


Statistica & Probabilità



Corso di laurea triennale in Fisica

Di Lernia Giulio

Indice

1	La probabilità e la distribuzione di probabilità	7
1.1	Assiomi di Kolgomorov	7
1.1.1	Definizione di probabilità frequentista	7
1.1.2	Teorema di Bayes	8
1.2	Variabili aleatorie	9
1.3	Probability Distribution Function (P.d.f)	10
1.3.1	Cumulative distribution function (C.d.f)	10
1.3.2	Istogrammi	12
1.3.3	Proprietà di una probability distribution function . . .	13
1.3.4	Valore di aspettazione di una probability distribution function	13
1.3.5	Momenti principali di una pdf per la popolazione e per un campione	14
1.4	Trasformazioni di distribuzioni di probabilità	16
1.5	Assenza di memoria per una distribuzione di probabilità . . .	19
1.6	Capitolo 1 - Guida allo studio	19
2	Modelli di probabilità	21
2.1	La distribuzione Uniforme	21
2.1.1	Proprietà della pdf	21
2.2	La distribuzione Gaussiana (o Normale)	22
2.2.1	Distribuzione cumulativa di una Gaussiana	23
2.2.2	Teorema Centrale del Limite	24
2.2.3	Conseguenze del TCL	24
2.3	Distribuzione di probabilità Log-normale	25
2.3.1	Proprietà della log-normale	25

INDICE

2.4	Distribuzione di Probabilità di Bernoulli	25
2.4.1	Proprietà della distribuzione Bernoulliana	26
2.5	Distribuzione di Probabilità Binomiale	26
2.5.1	Proprietà della distribuzione binomiale	26
2.5.2	La densità di probabilità di un'istogramma	27
2.6	Distribuzione Multinomiale	28
2.7	Distribuzione di Poisson	29
2.7.1	Proprietà della distribuzione di Poisson	29
2.7.2	Da eventi Poissoniani all'esponenziale	30
2.8	Distribuzione Esponenziale	31
2.8.1	Proprietà della distribuzione esponenziale	33
2.8.2	Decadimento Radioattivo	33
2.9	Comportamenti Asintotici delle distribuzioni	34
2.9.1	Proprietà asintotiche della Binomiale e Poissoniana	34
2.10	Distribuzione di χ^2	36
2.11	Capitolo 2 - Guida allo studio	37
3	Distribuzioni di probabilità multidimensionali	39
3.1	Probabilità per variabili aleatorie in più dimensioni	39
3.2	Distribuzione di probabilità marginale	40
3.3	Distribuzione di probabilità condizionata	40
3.4	Valore di aspettazione di una joint pdf	41
3.5	Varianza di una pdf multidimensionale	41
3.6	Correlazione	43
3.7	Variabili Statisticamente indipendenti	44
3.8	Cambiamento di variabili per una pdf multidimensionale	44
3.8.1	Propagazione degli errori	45
3.8.2	Decorrelazione delle variabili	46
3.9	Distribuzione di Gauss Multidimensionale	46
3.10	Capitolo 3 - Guida allo studio	47

4	Stime di Parametri	49
4.1	La statistica	49
4.2	Stimatori	49
4.3	Proprietà degli stimatori	50
4.3.1	Precisione e Accuratezza	52
4.3.2	Incertezze sulle stime	53
4.3.3	La Varianza come stimatore	54
4.3.4	Correzione di Bessel	55
4.4	Intervallo di confidenza	57
4.5	Capitolo 4 - Guida allo studio	58
5	Maximum Likelihood e Minimi Quadrati	61
5.1	La Verosomiglianza - Likelihood	61
5.2	Comportamento della likelihood	63
5.3	Minimum Variance Bound	64
5.3.1	Informazione di Fischer	64
5.3.2	Teorema di Rao - Cramér	64
5.4	Maximum Likelihood	65
5.5	Varianza dello stimatore di ML - Metodo Grafico	67
5.6	Extended likelihood	68
5.6.1	Applicazioni della Extendend Likelihood	69
5.7	Varianza di uno stimatore per più parametri	69
5.8	Metodo dei minimi quadrati	69
5.8.1	Funzionale Q^2	70
5.8.2	Valore di aspettazione di $\hat{\mu}_{MQ}$	70
5.8.3	Varianza dello stimatore $\hat{\mu}_{MQ}$	71
5.9	Varianza di un stimatore usando i MQ - Metodo grafico	71
5.10	Modelli lineari nei parametri - Regressione Lineare	73
5.10.1	Stime dei parametri	74
5.11	Sovrastima degli errori	76
5.11.1	Relazione tra il numero di parametri e il campione	76
5.11.2	Incertezze sulla variabile indipendente	76
5.11.3	Stima del fattore di sovrastima α	77
5.12	Teorema di Gauss-Markov	77

INDICE

5.13	Interpolazione ed Estrapolazione	78
5.14	Fit d'istogrammi	80
5.14.1	Binned Data - Minimi Quadrati	81
5.14.2	Binned Data - Maximum Likelihood	83
5.15	Capitolo 5 - Guida allo studio	84
6	Test d'ipotesi	87
6.1	Test del χ^2	87
6.1.1	Applicazione del test di χ^2	90
6.1.2	Distribuzione di probabilità del p-value	91
6.2	Errori di test statistici	92
6.2.1	Errori del I° tipo	92
6.2.2	Errori del II° tipo	92
6.3	Test di Kolgomorov-Smirnov	93
6.3.1	Costruzione del test	93
6.4	Confronto di una misura con il valore di riferimento	95
6.4.1	Distribuzione t-student	95
6.5	Intervalli di confidenza	97
6.5.1	Metodo della cintura di confidenza	98
6.6	Discovery Significance	99
6.7	Studio dei Residui e Pulls	100
6.8	Capitolo 6 - Guida allo studio	100

CAPITOLO 1

La probabilità e la distribuzione di probabilità

1.1 Assiomi di Kolgomorov

Come si definisce la probabilità secondo Kolgomorov?

Consideriamo degli eventi $E_1, E_2 \subset \Omega$ spazio campione, vogliamo costruire definiamo probabilità una funzione $P : \Omega \rightarrow [0, 1]$ che soddisfa le seguenti proprietà:

- $P(\Omega) = 1$
- $\forall A \subset \Omega$ si ha che $P(A) \geq 0$
- $\forall A, B \subset \Omega$, si ha che $P(A \cup B) = P(A) + P(B) - P(A \cap B)$. Se gli eventi sono indipendenti $A \cap B = \emptyset$, si ha che $P(A \cup B) = P(A) + P(B)$.

1.1.1 Definizione di probabilità frequentista

Come si definisce operativamente la probabilità secondo la formulazione frequentista?

La probabilità di un evento A é definita come il rapporto tra il numero di casi favorevoli (in cui avviene l'evento A) e il numero di casi possibili (la popolazione). Consideriamo di avere $\mathbf{N}$ eventi, e di contare il numero di volte in cui l'evento A , indicandolo come $\mathbf{n}(\mathbf{A})$. Definiamo la probabilità di

CAPITOLO 1. LA PROBABILITÀ E LA DISTRIBUZIONE DI PROBABILITÀ

un evento come:

$$\lim_{N \rightarrow \infty} \frac{n(A)}{N} \quad (1.1)$$

dove il limite é inteso in senso probabilistico ovvero al crescere del numero degli eventi.

Probabilità condizionata

Che cos'è la probabilità condizionata ?

Consideriamo una coppia di eventi $A, B \subset \Omega$ definiamo **probabilità condizionata** la probabilità che si verifichi l'evento A al verificarsi previamente dell'evento B.

$$P(A|B) = \frac{P(A \cap B)}{P(B)} \quad (1.2)$$

si dimostra che la probabilità condizionata soddisfa gli assiomi di Kolgomorov.

Nel caso di due eventi indipendenti, ovvero che il verificarsi di B non influenza la probabilità che si verifichi A

$$P(A|B) = P(A|\Omega) = P(A)$$

per due eventi indipendenti possiamo riscrivere la probabilità condizionata come:

$$P(A \cap B) = P(A) \cdot P(B) \quad (1.3)$$

1.1.2 Teorema di Bayes

Che cosa afferma il teorema di Bayes ?

Consideriamo due eventi $A, B \subset \Omega$ la probabilità nel caso di due eventi non indipendenti possiamo riscrivere la probabilità condizionata come:

$$P(A|B) \cdot P(B) = P(A \cap B) = P(B|A) \cdot P(A)$$

dunque l'equazione (1.2) può essere riscritta come :

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)} \quad (1.4)$$

tale espressione definisce il **teorema di Bayes**. La probabilità $P(A|B)$ viene detta " a posteriori " poiché permette di calcolare la probabilità di ,sapendo che si é verificato (o si verificherá con certezza assoluta) B.

La probabilità $P(A)$ si dice invece "a priori" poiché non condizionata da alcun altro evento o da alcuna conoscenza che potremmo avere sul suo verificarsi.

1.2 Variabili aleatorie

Che cos'è una variabile aleatoria ?

Una **variabile aleatoria** é una funzione definita sullo spazio campione a cui viene associato un sottoinsieme misurabile.

$$X : \Omega \rightarrow E \quad (1.5)$$

dove Ω é lo spazio di tutti gli esiti possibili, mentre E é l'insieme degli esiti al verificarsi di un determinato evento.

Nel caso in cui $\Omega \subseteq \mathbb{N}$ si ha che x viene definita **variabile casuale discreta**.

Se $\Omega \subseteq \mathbb{R}$, x viene definita **variabile aleatoria continua**, in questo caso la probabilità viene misurata su intervalli $P(a < x < b)$ e non piú sui singoli eventi come nel caso di quella discreta.

Esempio:

- Il conteggio del numero di volte in cui compare un certo valore di una misura é una variabile aleatoria discreta.
- La temperatura é una variabile aleatoria continua.


1.3 Probability Distribution Function (P.d.f)

Che cosa é una pdf e quali sono le sue proprietà ?


Si definisce densità di probabilità (p.d.f) una funzione che soddisfa le seguenti proprietà:

1. $pdf(x) : \Omega \subseteq \mathbb{R} \rightarrow \mathbb{R}^+$
2. $P(x < \hat{x} < x + dx) = pdf(x) \cdot dx$
3. $P(a < x < b) = \int_a^b pdf(x) \cdot dx \leq 1$
4. $P(x) = 0$, la probabilità in una singola misura é nulla.

per la definizione di probabilità nei punti 2) e 3) valgono gli assiomi di Kolgomorov.



(a) pdf(x)



(b) $P(a < x < b)$

1.3.1 Cumulative distribution function (C.d.f)

Che cosé una c.d.f.?

Si definisce distribuzione cumulativa la primitiva dell'integrale della pdf di una variabile aleatoria continua x :

$$cdf(x) = \int_a^x pdf(x) dx \quad (1.6)$$

ovvero si ha che:

$$\frac{d}{dx}cdf(x) = pdf(x) \quad (1.7)$$

di conseguenza la $cdf(x)$ descrive l'evolversi della probabilità di una variabile casuale.


Proprietà di una cdf

Una cdf gode delle seguenti proprietà:


- È una funzione monotona crescente e definita positiva
- $cdf(x) \in [0, 1]$
- $P(a \leq x \leq b) = cdf(b) - cdf(a)$

Corollario

Esiste una forma analitica della $cdf(x)$ di una r.v. $\iff$ la pdf ammette primitiva.



(a) $\int pdf(x)$





(b) $cdf(x)$

CAPITOLO 1. LA PROBABILITÀ E LA DISTRIBUZIONE DI PROBABILITÀ

1.3.2 Istogrammi

Che cos'è un istogramma ?

Consideriamo una variabile aleatoria x , di cui conosciamo $\{x_i\}_i^N$ valori distinti, utilizziamo tali grandezze come estremi per definire degli intervalli $\omega_k = [x_i, x_{i+1})$ disgiunti tra loro $\omega_k \cap \omega_m = \emptyset$ per $k \neq m$, sull'asse reale. Tali intervalli vengono definiti **bin**.




Ripetendo le misure contiamo il numero di volte n_i che un valore compare e cade all'interno di un'intervallo ω_k .

In questo modo posizionando sull'asse delle ordinate il numero di conteggi $n_i(x)$ si costruisce un istogramma.

Come si può utilizzare un istogramma per rappresentare una pdf ?

All'aumentare del numero di elementi $N \rightarrow \infty$ e diminuendo l'ampiezza dei bin $\Delta x \rightarrow 0$, ci si riconduce alla nozione di probabilità (1.1), in questo modo si passa a una pdf(x) continua. Per ogni bin è presente un punto x_i tale che



$$\int_{x_{min}^i}^{x_{max}^i} f(x) dx = f(x_i) \Delta x_i$$

si ha che

$$\lim_{\substack{N \rightarrow \infty \\ \Delta \rightarrow 0}} \int_{x_{min}^i}^{x_{max}^i} f(x) dx \rightarrow p_i \Rightarrow f(x_i) = \frac{p_i}{\Delta x_i}$$

1.3.3 Proprietà di una probability distribution function

Che cosa sono i momenti di una pdf?

Conoscere l'espressione analitica di una pdf è spesso poco significativo (soprattutto se la sua espressione non lascia intuire la forma della curva) in altri casi è impossibile definirla. Di conseguenza per studiare il comportamento di una pdf facciamo affidamento ad alcune grandezze che ne descrivono il comportamento, queste prendono il nome di **momenti**.

Tali momenti possiamo classificarli come:

- $E[x^m] = \int x^m \cdot pdf(x)dx$ prendono il nome di **momenti centrali di ordine m**.
- $E[(x - \mu)^m] = \int (x - \mu)^m \cdot pdf(x)dx$ prendono il nome di **momenti centrali**

il momento centrale di ordine 1 vale $E[(x - \mu)] = 0$.

1.3.4 Valore di aspettazione di una probability distribution function

Che cosa è il valore di aspettazione di una quantità rispetto ad una pdf ?

Data $x \in \Omega$ variabile aleatoria e $u(x) : \mathbb{R} \rightarrow \mathbb{R}$, il valore di aspettazione di $u(x)$ è definito come:

$$E[u(x)] = \int u(x) \cdot pdf(x)dx \quad (1.8)$$

dove $E[]$ è un operatore lineare:

- $E[x + y] = E[x] + E[y]$
- $E[\alpha x] = \alpha E[x] \quad \forall \alpha \in \mathbb{R}$

Per una variabile aleatoria discreta il valore di aspettazione è dato da:

$$E[x] = \sum_{i=1}^{+\infty} p_i x_i \quad (1.9)$$

1.3.5 Momenti principali di una pdf per la popolazione e per un campione

Che cosa sono e che cosa rappresentano la media, la varianza, l'assimetria e la curtosi di un campione ? e di una popolazione?

Sia $x \in \Omega$ una variabile aleatoria continua definiamo valore di aspettazione **media della popolazione** la grandezza:

$$\mu \equiv E[x] = \int x \cdot pdf(x) dx \quad (1.10)$$

Essa rappresenta il centro della distribuzione di probabilità .

Per un campione di N misure **la media** viene definita come:

$$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i \quad (1.11)$$

Si definisce **varianza della popolazione**:

$$\sigma^2 \equiv V[x] = E[(x - \mu)^2] = \int (x - \mu)^2 \cdot pdf(x) dx \quad (1.12)$$

la sua radice prende il nome di **deviazione standard** definisce l'ampiezza della pdf. La varianza può essere riscritta come:

$$V[x] = E[x^2] - E[x]^2 = E[x^2] - \mu^2 \quad (1.13)$$

Per un campione di N misure **la varianza** è data da:

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2 \quad (1.14)$$

mentre **la deviazione standard** è di un campione è data da:

$$\sigma = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2} \quad (1.15)$$

Tra i momenti centrali sono anche presenti la **skewness** per un campione di N misure:

$$\gamma_1 = \frac{1}{N} \sum_{i=1}^N \frac{(x - \mu)^3}{\sigma^3} \quad (1.16)$$

e per la popolazione:

$$\gamma_1 = \frac{E[(x - \mu)^3]}{\sigma^3} \quad (1.17)$$

tale grandezza definisce la simmetria di una distribuzione di probabilità rispetto al valore centrale dato dal valore di aspettazione μ per una popolazione. Se una distribuzione è simmetrica $\gamma_1 = 0$.




Figura 1.1: Simmetria di una distribuzione di probabilità

Si definisce indice di **kurtosi** di un campione di N elementi:

$$\gamma_2 = \frac{1}{N} \sum_{i=1}^N \frac{(x - \mu)^4}{\sigma^4} - 3 \quad (1.18)$$

mentre per la popolazione è data da:

$$\gamma_2 = \frac{E[(x - \mu)^4]}{\sigma^4} - 3 \quad (1.19)$$

tale stima fornisce informazioni sul peso delle code della distribuzione, nel senso che per code significative la distribuzione risulterà più schiacciata nell'intorno del valore μ , mentre per code meno incidenti sarà più piccata.

Stime di tendenza centrale

Che cosa sono moda, media e mediana di un campione? e di una popolazione?





Figura 1.2: Kurtosi di una distribuzione di probabilità



Definiamo **moda** di una popolazione il valore che definisce il massimo della pdf. Mentre per un campione la moda è definita dalla misura che possiede la frequenza relativa maggiore.

Mentre si definisce **mediana** il valore che divide in due parti uguali la pdf. Nel caso dei campioni le grandezze diventano rispettivamente il valore che compare con maggior frequenza e la misura che divide in due parti uguali il campione.

Per media e mediana di una distribuzione sono unici mentre per una distribuzione può avere più mode, in questi casi si parla di distribuzione **multimodale**.

1.4 Trasformazioni di distribuzioni di probabilità

Sia x una variabile aleatoria continua che segue una $pdf(x)$ e ipotizziamo di voler costruire una nuova variabile aleatoria y legandola ad x mediante una funzione $f(x)$, come definiamo la $pdf(y)$?

Sappiamo che la probabilità che una misura cada in un intervallo $[a,b)$ è data da




Figura 1.3: Distribuzione multimodale

$$P(a < x < b) = \int_a^b pdf(x) dx$$

Se effettuiamo un cambio di variabili $y=f(x)$ vogliamo innanzitutto che la trasformazione sia biunivoca dunque $f(x)$ deve essere monotona e continua. In questo modo applicando il teorema per il cambio di coordinate sotto segno d'integrale si ha che:

$$\frac{dy}{dx} = f'(x) \Rightarrow dx = f'(x)^{-1} dy \quad (1.20)$$

di conseguenza:

$$P(a < x < b) = \int_a^b pdf(x) dx = \int_{f(a)}^{f(b)} pdf(y) |f'(x)^{-1}| dy$$

per comodità si è posto un modulo affinché la funzione sia sempre positiva. In conclusione si ha che:

$$pdf(y) = pdf(x) |f'(x)| \quad (1.21)$$

Nel caso in cui abbia più di una dimensione è necessario che la funzione sia differenziabile e monotona e il modulo della derivata prima della fun-

CAPITOLO 1. LA PROBABILITÀ E LA DISTRIBUZIONE DI PROBABILITÀ

zione di cambio delle variabili viene sostituita dal modulo del determinante dell'inversa della matrice Jacobiana.

$$pdf(\mathbf{y}) = pdf(\mathbf{x}) \cdot |det J| \quad (1.22)$$

Come si osserva dalle equazioni (1.21) e (1.22) la nuova pdf(y) aumenta o diminuisce di un fattore rispetto alla pdf(x). Comunque sia la probabilità in un intervallo resta invariata.

Resta da discutere come cambiano i momenti della distribuzione, per farlo suddividiamo i risultati in due casi:

Caso in cui il cambio di variabile è lineare $y = ax+b$

Il valore di aspettazione per una pdf(y) dove $y = ax+b$ diventa:

$$E[y] = \int y \cdot pdf(y) dy = \int (ax + b) \cdot pdf(x) dx = y(\mu_x) \quad (1.23)$$

analogamente la varianza sarà data da:

$$V[y] = E[y^2] - E[y]^2 = a^2 \cdot V[x] \quad (1.24)$$

Caso in cui il cambio di variabile è non lineare $y = f(x)$

il valore di aspettazione e la varianza di una pdf(y) per $y = f(x)$ non lineare si stima approssimando con il polinomio di Taylor la funzione $y(x)$ in un'intorno di μ_x al secondo ordine:

$$y(x) \approx y(\mu_x) + \left. \frac{dy}{dx} \right|_{x=\mu_x} (x - \mu_x) + \frac{1}{2} \left. \frac{d^2y}{dx^2} \right|_{x=\mu_x} (x - \mu_x)^2$$

di conseguenza il valore di aspettazione è:

$$E[y] = \int y \cdot pdf(y) dy = y(\mu_x) + \left. \frac{dy}{dx} \right|_{x=\mu_x} \int (x - \mu_x) \cdot pdf(x) dx +$$

$$\begin{aligned}
 & + \frac{1}{2} \frac{dy^2}{dx^2} \Big|_{x=\mu_x} \int (x - \mu_x)^2 \cdot pdf(x) dx = \\
 & = y(\mu_x) + \frac{1}{2} \frac{dy^2}{dx^2} \Big|_{x=\mu_x} \cdot \sigma_x^2
 \end{aligned} \tag{1.25}$$

Mentre la varianza viene si ottiene dalla relazione:

$$V[y] = E[y^2] - E[y]^2 = \left(\frac{dy}{dx} \Big|_{x=\mu_x} \right)^2 \cdot \sigma_x^2 \tag{1.26}$$

L'espressione (1.26) è alla base della formula di propagazione degli errori.

1.5 Assenza di memoria per una distribuzione di probabilità

Gli eventi Poissoniani sono indipendenti l'uno dall'altro e la loro probabilità di decadimento è costante, dunque definita $q(t)$ la probabilità che non si verifichi un evento in un intervallo di tempo $[0, t]$ si ha che:

$$q(t + \delta t) = q(t)q(\Delta t) \tag{1.27}$$

la (1.27) definisce l'assenza di memoria di una distribuzione. Si può dimostrare che una distribuzione ha assenza di memoria $\iff$ è esponenziale.

1.6 Capitolo 1 - Guida allo studio

1. Come si definisce il concetto di probabilità secondo Kolmogorov?
2. Che legame c'è fra gli assiomi di Kolmogorov e i diagrammi di Eulero?
3. Che cosa è la probabilità condizionata?
4. Che cosa afferma il teorema di Bayes?

CAPITOLO 1. LA PROBABILITÀ E LA DISTRIBUZIONE DI PROBABILITÀ


5. Come si definisce operativamente la probabilità, secondo la formulazione frequentista?
6. Che cosa è una variabile casuale?
7. Che differenza c'è fra una variabile casuale discreta ed una continua?
8. Che cosa è una distribuzione di densità di probabilità e di quali proprietà deve godere?
9. Che cosa è la distribuzione cumulativa?
10. Che cosa è un istogramma?
11. Come si può utilizzare un istogramma per rappresentare una distribuzione di densità di probabilità?
12. Come si effettua un cambio di variabili per una distribuzione di probabilità?
13. Che cosa vuol dire che una distribuzione di probabilità ha assenza di memoria ?
14. Che cosa è il valore vero di un parametro di una distribuzione di densità di probabilità?
15. Che cosa sono i momenti di una distribuzione di densità di probabilità?
16. Che cosa sono i momenti centrali di una distribuzione di densità di probabilità?
17. Che cosa è il valore di aspettazione di una quantità rispetto ad una distribuzione di densità di probabilità?
18. Che cosa sono e che cosa rappresentano la media, la varianza, l'asimmetria e la curtosi di un campione? e di una popolazione?
19. Che cosa sono moda e mediana di un campione? e di una popolazione?

CAPITOLO 2

Modelli di probabilità

2.1 La distribuzione Uniforme

La distribuzione di probabilità uniforme per una variabile aleatoria x continua è definita come:



Tale distribuzione definisce una distribuzione di probabilità uguale per tutti le variabili aleatorie $x \in \Omega$.

2.1.1 Proprietà della pdf

Il valore atteso della distribuzione uniforme e la sua varianza sono date da:

$$E[x] = \int_a^b \frac{x}{b-a} dx = \frac{b+a}{2} \quad (2.1)$$

$$V[x] = \int_a^b \frac{1}{b-a} \left(x - \frac{b+a}{2}\right)^2 dx = \frac{(b-a)^2}{12} \quad (2.2)$$


Per una distribuzione di questo tipo si ha che la simmetria e la curtosi rispettivamente hanno valore nullo.

Inoltre tale pdf gode della proprietà di **riproduttività** ovvero date due variabili casuali x e y che seguono la pdf uniforme si ha che la nuova variabile aleatoria $z = x + y$ segue una distribuzione di probabilità pdf(z) con media $\mu_z = \mu_x + \mu_y$ e varianza $\sigma_z^2 = \sigma_x^2 + \sigma_y^2$.

Un'altra proprietà importante della pdf è data dal fatto che se si ha una variabile aleatoria x che segue una distribuzione uniforme, la variabile casuale $y = f(x)$ seguirà anch'essa la medesima distribuzione di probabilità.


Poichè la pdf possiede una forma analitica è possibile definirne la cdf:

$$cdf(x) = \int_a^x \frac{dx}{b-a} = \frac{1}{b-a}(x-a)$$



2.2 La distribuzione Gaussiana (o Normale)

Data una variabile aleatoria $x \in \Omega$ continua la distribuzione di probabilità Gaussiana è definita come:



Per una distribuzione Gaussiana si ha che la media, la moda e la mediana coincidono essendo una distribuzione simmetrica ovvero $\gamma_1, \gamma_2 = 0$. Media, Varianza e deviazione standard coincidono con quelle definite al capitolo precedente. Gode della proprietà di **riproduttività** definita nella sezione della distribuzione uniforme.


Una caso speciale di Gaussiana è quella **standardizzata** che è espressa come:

$$G(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

2.2.1 Distribuzione cumulativa di una Gaussiana

La pdf Gaussiana non ammette primitiva e la sua cdf viene calcolata numericamente e prende il nome di **funzione d'errore**, abbreviata con $\text{erf}(x)$.

$$\text{erf}(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt$$



2.2.2 Teorema Centrale del Limite

La distribuzione Gaussiana è particolarmente importante poichè per essa vale un importante risultato.

Teorema

Si ipotizzi di avere N variabile aleatorie $\{x_i\}_i^N$ indipendenti tra loro e ciascuna di esse segue una distribuzione di probabilità $f_i(x)$ con $E[x_i] < \infty$ e $V[x_i] < \infty$, e definiamo una nuova variabile aleatoria $s = \sum_{i=1}^N x_i$ che segue una distribuzione pdf(s), allora si avrà che al crescere del numero di variabili:

$$\lim_{N \rightarrow \infty} pdf(s) \rightarrow G(s, \mu_s, \sigma_s)$$

$$\text{dove } \mu_s = \sum_{i=1}^N \mu_i \text{ e } \sigma_s^2 = \sum_{i=1}^N \sigma_i^2 .$$

Corollario della media

Date N variabili aleatorie $\{x_i\}_i^N$ indipendenti ed identicamente distribuite, ovvero che per ogni variabile si ha la stessa distribuzione di probabilità $f(x)$ e ipotizzando che $\forall i$ si ha che μ_i e σ_i^2 siano finite, definita una nuova variabile aleatoria $\bar{x} = \frac{\sum_{i=1}^N x_i}{N}$ che segue una pdf $f(\bar{x})$, si ha che al crescere del numero di variabili:

$$\lim_{N \rightarrow \infty} f(\bar{x}) \rightarrow G(\bar{x}, \mu, \frac{\sigma}{\sqrt{N}})$$

dunque si ha che la pdf delle medie campionarie di un campione che cresce converge alla distribuzione Gaussiana.

2.2.3 Conseguenze del TCL

Quando effettuiamo una misura in un esperimento in generale possiamo definirla come la somma del valore vero x_0 e di un errore ϵ che è una variabile aleatoria.

$$x = x_0 + \epsilon$$

La maggior parte delle misure che si effettuano sono la somma di variabili aleatorie, come per esempio errori intrinseci ed errori sperimentali. Per esempio quando misuriamo un oggetto con un metro, inseriamo all'interno della misura degli errori, che possono dipendere sia dalle condizioni sperimentali che dall'operatore (Diottrie, stabilità del polso, ecc...), tali errori si sommano tra loro. Il teorema centrale del limite risulta essere importante perché ci dice che la somma di tali errori al crescere della dimensione del campione segue una distribuzione di probabilità Gaussiana, permettendoci di applicare alcuni metodi statistici per la stima dei parametri e garantendo delle proprietà significative alla stima.

2.3 Distribuzione di probabilità Log-normale

Preso una variabile aleatoria $x \in \Omega$ che segue una distribuzione Gaussiana, costruiamo una nuova variabile aleatoria y legata alla precedente dalla relazione $y = e^x$, in questo modo si definisce la distribuzione log-normale applicando un cambio di variabile alla $G(x)$ di partenza, il metodo con cui si effettua un cambio di variabile verrà presentato nei capitoli successivi.

$$f(x, \mu, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} \frac{1}{x} e^{-\frac{(\log(x)-\mu)^2}{2\sigma^2}}$$

2.3.1 Proprietà della log-normale

Il valore di aspettazione e varianza della log-normale sono dati da:

$$E[x] = e^{(\mu + \frac{1}{2}\sigma^2)} \quad (2.4)$$

$$V[x] = e^{(2\mu + \sigma^2)} e^{(\sigma^2 - 1)} \quad (2.5)$$

2.4 Distribuzione di Probabilità di Bernoulli

Sia $x \in \Omega = \{0, 1\}$ una variabile aleatoria discreta, a cui è possibile associare una probabilità $p \in [0, 1]$. Definiremo che l'evento x si è realizzato con

successo quando $P(x = 1) = p$, mentre l'insuccesso con $P(x = 0) = (1-p)$. Dunqua la pdf(x) è data da:

$$f(x, p) = p^x (1 - p)^{1-x}$$

2.4.1 Proprietà della distribuzione Bernoulliana

Per una distribuzione di Bernoulli media e varianza sono date:

$$E[x] = \sum_{\{0,1\}} x f(x, p) = p \quad (2.6)$$

$$V[x] = \sum_{\{0,1\}} (x - p)^2 f(x, p) = p(1 - p) \quad (2.7)$$

2.5 Distribuzione di Probabilità Binomiale

Si consideri un insieme di N osservazioni indipendenti, che seguono una distribuzione di Bernoulli. Contiamo il numero di volte k in cui l'evento ha successo rispetto al numero di tentativi effettuati, tale insieme è il nostro campione. Se si ripete l'esperimento effettuando sempre N tentativi, il numero di successi n sarà distribuita secondo la distribuzione binomiale:

$$B(k|N, p) = \binom{N}{k} p^k (1 - p)^{N-k}$$

notare che a differenza delle distribuzioni viste fino ad ora, la distribuzione binomiale in realtà rappresenta la probabilità stessa di una variabile aleatoria k , come anche la Bernoulliana.

2.5.1 Proprietà della distribuzione binomiale

Per una distribuzione binomiale il valore di aspettazione e la varianza sono definite da :

$$E[k] = \sum_k k \binom{N}{k} p^k (1 - p)^{N-k} = Np \quad (2.8)$$

$$V[k] = E[k^2] - E[k]^2 = Np(1-p) \quad (2.9)$$

la simmetria è data da:

$$\gamma_1 = \frac{1-2p}{\sqrt{Np(1-p)}} \quad (2.10)$$

dove $\gamma_1 \rightarrow 0$ per $N \rightarrow \infty$ o per $p = \frac{1}{2}$.


la kurtosi invece si esprime come:

$$\gamma_2 = \frac{1-6p}{Np(1-p)} \quad (2.11)$$

dove $\gamma_2 \rightarrow 0$ per $N \rightarrow \infty$ e $p = \frac{1}{6}$. Inoltre la distribuzione binomiale gode della proprietà di **riproduttività**

2.5.2 La densità di probabilità di un'istogramma

Consideriamo di avere una variabile aleatoria x di cui effettuiamo N misurazioni, ciascuna misurazione segue una $\text{pdf}(x)$.



L'operazione è equivalente a campionare N volte una $\text{pdf}(x)$. Posto che le $\{x_i\}_i^N$ misure siano il campione di riferimento, la statistica si pone obiettivo quello di ricostruire partendo dal campione le caratteristiche di una $\text{pdf}(x)$. Per farlo si procede a costruire un istogramma e a contare il numero di eventi k_i che cadono all'interno di un bin e rap-

presentare tale numero con una barra. Il numero di misure k_i che cade all'interno di un bin è una variabile aleatoria. Di conseguenza studiando il comportamento di un singolo bin $[a,b)$, il numero di misure k_i è descritto da una distribuzione di probabilità, poichè un fenomeno cade o non cade all'interno dell'intervallo la $\text{pdf}(k_i)$ è quella di Bernoulli. Reiterando l'esperimento sullo stesso bin il numero di successi k_i seguirà una $\text{pdf}(k)$ di una


binomiale $B(k|N, p)$ dove la probabilità è $p = \int_a^b pdf(x)dx$ sull'intervallo del bin associato.

Un conteggio di misure è soggetto a fluttuazioni statistiche, e al crescere del numero delle misure l'istogramma assumerà la distribuzione di probabilità $pdf(x)$ della variabile aleatoria X misurata.

Se ipotizziamo che X abbia una distribuzione uniforme, valore di aspettazione e varianza di un conteggio coincideranno con quella della distribuzione Binomiale.

I metodi statistici che possono essere applicati a misure binnate richiedono che i conteggi k_i siano variabili aleatorie indipendenti, affinché tale condizione risulti essere verificata si hanno due strategie possibili:

- Se la dimensione dei bin è piccola e la probabilità è sufficientemente piccola allora la covarianza è pressoché nulla. Di conseguenza le variabili k_i sono indipendenti tra loro e dunque ciascuna distribuita come una binomiale.
- Se il numero di eventi N è molto grande e la probabilità p_i è piccola la distribuzione di probabilità dei conteggi è approssimabile a quella di una distribuzione Poissoniana.



2.6 Distribuzione Multinomiale

Considerando quanto discusso nella sezione precedente per ogni singolo bin che si è costruito nell'istogramma, si definisce una probabilità multinomiale:

$$Multi(k_1, k_2, \dots, p_1, p_2, \dots) = \frac{N!}{k_1! \cdot k_2! \dots} p^{k_1} p^{k_2} \dots \quad (2.12)$$

Valore di aspettazione e varianza rimangono le medesime per ogni singolo bin, solo che i conteggi k_i non sono variabili aleatorie indipendenti tra loro, in questo caso si ha la **covarianza**:

$$\text{cov}[k_i, k_j] = -N \cdot p_i \cdot p_j \quad (2.13)$$

2.7 Distribuzione di Poisson

La distribuzione di Poisson è una distribuzione di probabilità discreta che esprime la probabilità che un numero di eventi indipendenti si verifichi in un certo intervallo di spazio o tempo fissato con una frequenza media costante. Il verificarsi dell'evento a un tempo t non influenza il verificarsi del medesimo in un intervallo di tempo successivo o precedente al tempo t . La probabilità di contare k eventi in un intervallo di tempo unitario è:

$$\text{Poiss}(k, \lambda) = \frac{e^{-\lambda} \cdot \lambda^k}{k!} \quad (2.14)$$

lo spazio campione rispetto alla quale è definita è tutto $\mathbb{N}$

2.7.1 Proprietà della distribuzione di Poisson

Il valore di aspettazione e la varianza della distribuzione di Poisson sono:

$$E[k] = \sum_{k=0}^{\infty} k \cdot \frac{e^{-\lambda} \cdot \lambda^k}{k!} = \lambda \quad (2.15)$$

$$V[k] = \sum_{k=0}^{\infty} (k - \lambda)^2 \cdot \frac{e^{-\lambda} \cdot \lambda^k}{k!} = \lambda \quad (2.16)$$

si nota che all'aumentare della media aumenta anche la varianza.

L'indice di simmetria e kurtosi sono dati da:

$$\gamma_1 = \frac{1}{\sqrt{\lambda}} \quad (2.17)$$

$$\gamma_2 = \frac{1}{\lambda} \quad (2.18)$$

per $\lambda \rightarrow \infty$ la distribuzione di Poisson diventa più simmetrica. Inoltre la distribuzione di Poisson gode della proprietà di **riproduttività**.

2.7.2 Da eventi Poissoniani all'esponenziale

Il modello su cui si basa la distribuzione di Poisson è dato dalle seguenti assunzioni:

- la probabilità che un evento avvenga in un intervallo di tempo $[t, t+dt]$ è data da $p \cdot dt$, dove p è un valore costante e indipendente da t ;
- la probabilità di avere più di un evento nell'intervallo dt è nulla.
- gli eventi sono indipendenti tra loro.

Definiamo $E = \{\text{nessun evento avvenuto in } [0, t+dt]\}$ e la funzione $q(t) = \{\text{probabilità di nessun evento in } [0, t]\}$, posta I come l'informazione a priori (ex: tempo di decadimento medio) si ha che la probabilità che si verifichi E essendosi già verificato I è:

$$P(E|I) \equiv q(t + dt) \quad (2.19)$$

Dove q ha come argomento la lunghezza degli intervalli di tempo; possiamo riformulare E come l'intersezione di due eventi $E_1 = \{0 \text{ eventi in } [0, t]\}$ ed $E_2 = \{0 \text{ eventi in } [t, t+dt]\}$, dunque 2.19 può essere riscritta come:

$$P(E|I) = P(E_1, E_2|I) = P(E_1|I)P(E_2|E_1, I)$$

poichè per ipotesi E_1 ed E_2 sono indipendenti dato che il verificarsi di un evento in un intervallo di tempo non influenza il verificarsi del medesimo evento in un intervallo successivo si ha che:

$$P(E|I) = P(E_1|I)P(E_2|I) \quad (2.20)$$

dove $P(E|I) = q(t + dt)$, $P(E_1|I) = q(t)$ e $P(E_2|I) = 1 - p dt$. Dunque:

$$q(t + dt) = q(t) \cdot (1 - p dt) \Rightarrow \frac{q(t + dt) - q(t)}{dt} = -q(t)p \quad (2.21)$$

questo è equivalente all'equazione differenziale al primo ordine:

$$\frac{dq}{q} = -p \cdot dt \iff q(t) = q(0)e^{-pt}$$

dove $q(0)$ è determinata normalizzando la distribuzione di probabilità. Per eventi che occorrono in modo Poissoniano la probabilità di non avere eventi in un intervallo $[0, x]$ è data da una esponenziale.

Per comodità poniamo $q(0)=1$. Definiamo $A = \{1 \text{ evento in } [t_1, t_1+dt_1]\}$ ed $B = \{0 \text{ eventi in } [0, t_1]\}$ definiamo:

$$P(A, B|I) = P(A|I) \cdot P(B|I) = e^{-pt}(p \cdot dt) \quad (2.22)$$

ipotizzando di costruire una catena di eventi in cui si realizza e non si realizza un evento per tempi ordinati si ha che:

$$P(A, B|I) = e^{-pt_1} \cdot p \cdot dt_1 \cdot e^{-p(t_2-t_1)} \cdot p \cdot dt_2 \cdots = e^{-pt} p^n dt_1 \cdots dt_n \quad (2.23)$$

Per definire una probabilità che si realizzino n eventi in un intervallo di tempo $[0, t]$, a prescindere dal tempo preciso in cui avvengono, dobbiamo sommare le probabilità definite in (2.23):

$$P(n|p, t, I) = e^{-pt} p^n \int_0^{t_2} dt_1 \cdot \int_0^{t_2} dt_2 \cdots \int_0^t dt_n \quad (2.24)$$

il prodotto d'integrali ha come soluzione $\frac{t^n}{n!}$ e dunque:

$$P(n|p, t, I) = \frac{(pt)^n}{n!} e^{-pt} = \frac{\lambda^n}{n!} e^{-\lambda} \quad (2.25)$$

2.8 Distribuzione Esponenziale

La distribuzione esponenziale è la distribuzione dei tempi che intercorrono tra due eventi Poissoniani, ovvero la probabilità che nessun evento si verifichi. Infatti consideriamo k il numero di eventi definiti da una pdf Poissoniana con frequenza p , avvenuti in un intervallo di tempo $[0, t]$. Allora si ha:

$$P(k, p) = \frac{(pt)^k}{k!} e^{-pt}$$


Se misuriamo la probabilità che nessun evento si verifichi in un tempo $t < T$ si avrà:

$$P(0|p, t) = \frac{(pt)^0}{0!} e^{-pt} = e^{-pt}$$

e si ha dunque una pdf Poissoniana. Se rileviamo il medesimo evento per $T > t$ si avrà che la probabilità dell'evento avvenuto al tempo T è descritta dalla medesima pdf per il tempo t antecedente:

$$P(0|p, T > t) = P(0|p, t) = e^{-pt}$$

Dunque la distribuzione di probabilità che intercorre da tra due eventi Poissoniani è esponenziale.



ed è definita da:

$$pdf(t, \lambda) = \lambda \cdot e^{-\lambda t} \quad (2.26)$$

dove $\tau = E[t]$ è il tempo medio tra due eventi consecutivi, e vale la relazione $\lambda = \frac{1}{\tau}$ dove λ è il parametro della Poissoniana che determina la frequenza media di eventi.

2.8.1 Proprietà della distribuzione esponenziale

Il valore di aspettazione e varianza sono date dalle quantità:

$$E[t] = \tau = \frac{1}{\lambda} \quad (2.27)$$

$$V[t] = \tau^2 = \frac{1}{\lambda^2} \quad (2.28)$$

mentre i parametri di simmetria della distribuzione dati da simmetria e kurtosi:

$$\gamma_1 = 2 \quad (2.29)$$

$$\gamma_2 = 6 \quad (2.30)$$

come si osserva dai momenti essendo γ_1 e γ_2 costanti la distribuzione esponenziale non può tendere ad una Gaussiana al crescere del numero di eventi.

2.8.2 Decadimento Radioattivo

Si consideri un campione di materiale radioattivo contenente N_0 nuclei al tempo $t=0$ per un singolo nucleo padre la probabilità di decadimento segue una distribuzione esponenziale il cui τ tempo medio di decadimento è dato dalla meccanica quantistica. Gli eventi di decadimento sono **indipendenti** tra di loro.

La variazione del numero dei nuclei in un intervallo di tempo Δt sarà proporzionale al numero di nuclei restanti:

$$-\frac{dN}{dt} = \lambda N \quad (2.31)$$

dove λ è la frequenza media di decadimento. Di conseguenza il decadimento radioattivo è definito dalla funzione:

$$N(t) = N_0 e^{-\lambda t} \quad (2.32)$$

che possiamo riscrivere come :

$$N(t) = N_0 e^{-\frac{t}{\tau}} \quad (2.33)$$

Se $\tau \gg t$ tempo di osservazione, la frequenza media dei decadimenti è costante nel tempo e di conseguenza la probabilità di osservare k decadimenti in un campione di N nuclei è data dalla distribuzione di Poisson con $\lambda = \frac{1}{\tau}$.

2.9 Comportamenti Asintotici delle distribuzioni

2.9.1 Proprietà asintotiche della Binomiale e Poissoniana

Binom($k|N, p$) $\rightarrow$ Poisson($k, \mu = N \cdot p$)

La relazione tra distribuzione Binomiale e Poissoniana si costruisce assumendo di prendere un intervallo Δt e di dividerlo in N intervalli di dimensione dt tali per cui:

- in ciascun dt cada uno solo evento(tale ipotesi è verificata solo se il numeri di eventi è molto grande);
- la probabilità in un singolo intervallo dt è $p = \frac{\lambda}{N}$ ed è finita;
- gli eventi che cadono in ogni intervallo dt sono indipendenti tra loro.

Essendo gli eventi indipendenti tra loro per ipotesi ciascuno di essi segue una distribuzione di Bernoulli. Tali condizioni consentono di usare una distribuzione binomiale per descrivere eventi Poissoniani.

Per induzione si ha che per $k=0$ posto $\lambda = N \cdot p$

$$B\left(0|N, \frac{\lambda}{N}\right) = \left(1 - \frac{\lambda}{N}\right)^N \underset{N \rightarrow \infty}{=} \frac{\lambda^0}{0!} e^{-\lambda}$$

dunque la relazione per $k-1$ sarà verificata e:

$$B\left(k-1|N, \frac{\lambda}{N}\right) \underset{N \rightarrow \infty}{=} \frac{\lambda^{k-1}}{(k-1)!} e^{-\lambda}$$

Allora si dimostra che dall'espressione binomiale:

$$\frac{B\left(k|N, \frac{\lambda}{N}\right)}{B\left(k-1|N, \frac{\lambda}{N}\right)} = \frac{Np - (k-1)p}{k(1-p)} \approx_{p \rightarrow 0} \frac{\lambda}{k}$$

dunque:

$$B\left(k|N, \frac{\lambda}{N}\right) = \frac{\lambda}{k} \cdot B\left(k-1|N, \frac{\lambda}{N}\right) \rightarrow \frac{\lambda^k}{k!} e^{-\lambda}$$

Si dimostra inoltre che data una distribuzione Binomiale $B(k|N, p) \rightarrow G(k, \mu, \sqrt{\mu})$ al crescere del numero di misure $N \rightarrow \infty$ per $\mu = N \cdot p$ costante.

Vale anche il fatto che per una Poissoniana si ha $Poiss(k, \lambda) \rightarrow G(k, \lambda, \sqrt{\lambda})$ per $\lambda \rightarrow \infty$.




Figura 2.1: Mappa delle distribuzioni asintotiche

2.10 Distribuzione di χ^2


La distribuzione di χ^2 nasce nel contesto della modellazione di dati per la stima di parametri usando i metodi di maximum likelihood e minimi quadrati. Dato un campione di n punti $\{(x_i, y_i)\}_i^N$ e un modello $f(x, \underline{\theta})$, dipendente da m parametri $\underline{\theta}$ si valuta la bontà del modello nell'approssimare i dati usando la funzione di Q^2 definita come:

$$\chi^2 = \sum_{i=1}^n \frac{[y_i - f(x_i, \underline{\theta})]^2}{\sigma_i^2} \quad (2.34)$$


dove le σ_i^2 sono gli errori sulle n misure di y_i .

Per le misure y che seguono una pdf Gaussiana, la pdf del χ^2 è data distribuzione:

$$\chi^2 = \frac{1}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})} z^{(\frac{n}{2}-1)} e^{-\frac{z}{2}}$$



dove n prende il nome di **numero di gradi di libertà** e $\Gamma(x)$ è la funzione gamma.



La distribuzione di χ^2 possiede una distribuzione cumulativa e gode delle seguenti proprietà:

- **media:** $E[n] = n$
- **Varianza:** $V[n] = 2n$
- è riproduttiva
- **moda:** $n-2$

χ^2 ridotto

Si definisce χ^2 ridotto data dal rapporto $\frac{\chi_N^2}{n}$ e la sua media è pari a 1.




Figura 2.2: Distribuzione di χ^2 ridotto e rispetti distribuzione cumulativa.

2.11 Capitolo 2 - Guida allo studio

1. Che espressione analitica hanno e quali sono le proprietà notevoli delle distribuzioni uniforme, Gaussiana, lognormale?
2. Che cosa sostiene il teorema centrale del limite?
3. In particolare, quali sono le ipotesi nelle quali è valido?
4. Quale è un contro esempio notevole che dimostra la necessità delle ipotesi?
5. Che differenza c'è fra una distribuzione di densità di probabilità definita su dominio continuo ed una distribuzione di probabilità definita su dominio discreto?
6. Come sono definite e quali sono le proprietà delle distribuzioni binomiale e di Bernoulli?

7. Che applicazione notevole ha la distribuzione binomiale nell'interpretazione degli istogrammi di dati?
8. Come sono definite e quali sono le proprietà della distribuzione di Poissoniana?
9. Che ruolo hanno e come si utilizzano le distribuzioni Binomiale e Poissoniana nella lettura degli istogrammi che rappresentano la raccolta di misure?
10. Come si applica il teorema centrale del limite alla distribuzione di Poisson ed a quella binomiale?
11. Quali sono le distribuzioni di probabilità che caratterizzano i decadimenti radioattivi?
12. In quali condizioni sono una buona rappresentazione delle misure?
13. In quali circostanze è utilizzabile la distribuzione di Poisson nell'ambito delle misure di decadimenti radioattivi?
14. Che legame c'è fra la distribuzione di Poisson e quella esponenziale?
15. Che cosa è una distribuzione multinominale?
16. Quali sono le proprietà della distribuzione del chiquadro?

CAPITOLO 3

Distribuzioni di probabilità multidimensionali

3.1 Probabilità per variabili aleatorie in più dimensioni

Quando un evento è identificato da un vettore $\underline{x}$, si parla di distribuzioni di probabilità multidimensionali o **joint pdf (probabilità congiunta)**.


$$pdf(\underline{x}) : A \subseteq \mathbb{R}^n \rightarrow \mathbb{R}^+$$

e la cdf per estensione della definizione mono-dimensionale è:

$$cdf(\underline{x}) = \int_A pdf(\underline{x}) \cdot d\underline{x}$$

la probabilità di un evento per una variabile continua $\underline{x}$ è definita su una regione di spazio $A \subseteq \mathbb{R}^n$:

$$P(\underline{x} \in A) = \int_A pdf(\underline{x}) \cdot d\underline{x}$$



Tale definizione di probabilità verifica gli assiomi di Kolgomorov.

3.2 Distribuzione di probabilità marginale

Data una distribuzione di probabilità multidimensionale $pdf(x_1, \dots, x_n)$ si definisce **distribuzione di probabilità marginale**:

$$f_{x_i}(x_1, \dots, x_i, \dots, x_n) = \int pdf(x_1, \dots, x_i, \dots, x_n) dx_1 \cdots dx_n \quad (3.1)$$




Figura 3.1: Distribuzione di probabilità marginale per una $pdf(x,y)$

Esempio

Nel caso bi-dimensionale si ha che le rispettive distribuzioni marginali di una joint $pdf(x_1, x_2)$ sono date da:

$$f_x(y) = \int pdf(x, y) dy \quad f_y(x) = \int pdf(x, y) dx \quad (3.2)$$

3.3 Distribuzione di probabilità condizionata

Per semplicità consideriamo una distribuzione di probabilità rispetto a due variabili aleatorie x ed y e le rispettive distribuzioni marginali f_x e f_y . Vogliamo determinare la probabilità che $P(x|y = y_0)$ o $P(y|x = x_0)$. Consideriamo due eventi $A, B \subset \Omega$ disgiunti. Possiamo identificare le pdf come:

- $P(A \cap B) \rightarrow$ joint pdf
- $P(A) \rightarrow$ pdf marginale
- $P(A|B) \rightarrow$ pdf condizionata

Definiamo L'evento $A = \{y \mid x \in [x_0, x_0 + dx] , y \in \mathbb{R}\}$ e l'evento $B = \{x \mid y \in [y_0, y_0 + dx] , x \in \mathbb{R}\}$. Le probabilità associate ai singoli eventi sono $P(A) = f_x$ e $P(B) = f_y$. Mentre la probabilità congiunta è $P(A \cap B) = \int pdf(x_0, y_0) dx dy$.

Di conseguenza possiamo scrivere la probabilità condizionata come:

$$pdf(x|y = y_0) = P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{pdf(x, y_0)}{f_x(y_0)} \quad (3.3)$$

e analogamente:

$$pdf(y|x = x_0) = \frac{pdf(x_0, y)}{f_y(x_0)} \quad (3.4)$$

3.4 Valore di aspettazione di una joint pdf

Per una distribuzione di probabilità congiunta abbiamo che il valore di aspettazione è definito da un vettore:

$$E[\underline{x}] = \begin{bmatrix} \mu_x \\ \mu_y \end{bmatrix} = \begin{bmatrix} \int \int x \cdot pdf(x, y) dx dy \\ \int \int y \cdot pdf(x, y) dx dy \end{bmatrix} \quad (3.5)$$

3.5 Varianza di una pdf multidimensionale

Nel caso della Varianza, le componenti di una variabile aleatoria multidimensionale $\underline{x}$ possono essere legate tra loro, ovvero avere una relazione nel modo in cui variano, tale legame prende il nome di **covarianza**. Per due componenti x_i e x_j con $i \neq j$ si ha che:

$$\sigma_{i,j}^2 = E[(x_i - \mu_i)(x_j - \mu_j)] = E[x_i x_j] - E[x_i]E[x_j] \quad (3.6)$$

mentre

CAPITOLO 3. DISTRIBUZIONI DI PROBABILITÀ MULTIDIMENSIONALI

$$\sigma_{i,i}^2 = E[(x_i - \mu_i)^2] \quad (3.7)$$

di conseguenza la varianza di una pdf($\underline{x}$) multidimensionale è rappresentata da una matrice che prende il nome di **matrice di covarianza** ed ha dimensione $n \times n$ nel caso $\underline{x}$ sia un vettore dimensione n .

$$V[\underline{x}] = \begin{bmatrix} V[x_1] & \cdots & Cov[x_1, x_n] \\ \vdots & \ddots & \vdots \\ Cov[x_n, x_1] & \cdots & V[x_n] \end{bmatrix} \quad (3.8)$$

Nel caso in cui le componenti della variabile aleatoria $\underline{x}$ siano indipendenti tra loro si ha che la covarianza è nulla e dunque la (3.3) diventa una matrice diagonale.

$$V[\underline{x}] = \begin{bmatrix} V[x_1] & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & V[x_n] \end{bmatrix} \quad (3.9)$$

La covarianza gode delle seguenti proprietà:

- Avere $Cov[x_i, x_j] = 0$ non implica necessariamente che le due variabili aleatorie siano statisticamente indipendenti.
- Se due variabili aleatorie sono statisticamente indipendenti
 $\Rightarrow Cov[x_i, x_j] = 0$
- Se due variabili aleatorie sono linearmente dipendenti
 $\Rightarrow Cov[x_i, x_j] = 0$
- La matrice di covarianza è simmetrica $\Rightarrow$ è diagonalizzabile.




Figura 3.2: Esempi di come la covarianza si presenta in una distribuzione

3.6 Correlazione

Gli elementi V_{ij} della matrice di covarianza misurano il grado di correlazione tra le variabili x_i e x_j . Dato che ogni variabili mostra una varianza finita e positiva è utile confrontare la covarianza rispetto alle loro rispettive varianze, per farlo si introduce il coefficiente di correlazione:

$$\rho_{ij} = \frac{Cov[x_i, x_j]}{\sigma_i \sigma_j} \quad (3.10)$$

tale grandezza $\rho_{ij} \in [-1, 1]$.




Figura 3.3: Indice di correlazione di Pearson per un campione di misure.

3.7 Variabili Statisticamente indipendenti

Applichiamo la definizione di probabilità congiunta data dall'equazione (3.3), poichè per ipotizziamo che $P(x_2|x_1)$ e x_2 non dipenda da x_1 avremo che:

$$pdf(x_2|x_1) = \frac{pdf(x_1, x_2)}{f_{x_1}} \Rightarrow pdf((x_1, x_2) = f_{x_1} \cdot pdf(x_2|x_1)$$

si ha che

$$f_{x_2}(x_1) = \int pdf(x_1, x_2) dx_1 = pdf(x_2|x_1) \int f_{x_1} dx_1 = pdf(x_2|x_1)$$

dunque si ha che:

$$pdf(x_1, x_2) = f_{x_1} \cdot f_{x_2}$$

Definizione d'indipendenza

Due variabili aleatorie x_1 ed x_2 descritte da una joint $pdf(x_1, x_2)$ si definiscono **indipendenti** $\iff$ la joint $pdf(x_1, x_2) = pdf(x_1) \cdot pdf(x_2)$ dove $pdf(x_1)$ e $pdf(x_2)$ coincidono con le marginali.

Teorema

Due variabili aleatorie x_1 ed x_2 descritte da una joint $pdf(x_1, x_2)$ sono indipendenti $\Rightarrow$ la covarianza può essere scritta come:

$$E[(x_1 - \mu_{x_1})(x_2 - \mu_{x_2})] = E[(x_1 - \mu_{x_1})] \cdot E[(x_2 - \mu_{x_2})] \quad (3.11)$$

3.8 Cambiamento di variabili per una pdf multidimensionale

La matrice della varianza (3.6) è diagonalizzabile, questo vuol dire che esiste un cambio di base che la diagonalizza, in fisica è equivalente ad avere un cambio di variabile. Sperimentalmente raccolto un campione di misure esiste sempre un cambio di variabile tale per cui la matrice di covarianza è diagonalizzabile. Anche se con un cambio di variabili le grandezze diventano

decorrelate $Cov[x_i, x_j] = 0$ questo non vuol dire che siano statisticamente indipendenti.

Analogamente al caso mono-dimensionale per il cambio di variabili si ha che date delle funzioni:

$$\begin{cases} x = u(\alpha, \beta) \\ y = w(\alpha, \beta) \end{cases}$$

la join pdf nelle nuove coordinate sarà data da:

$$pdf(\alpha, \beta) = pdf(x, y) \cdot |det J| \quad (3.12)$$

dove J è la matrice Jacobiana associata alla trasformazione.

3.8.1 Propagazione degli errori

Ipotizziamo di avere un insieme di N misure $\{x_i\}_i^N$ e usiamo tali valori come componenti di un vettore $\underline{x} \in \mathbb{R}^N$, descritto da una pdf($\underline{x}$) di cui conosciamo $\underline{\mu}$ e matrice di covarianza $V[\underline{x}]$, vogliamo calcolare $y = u(\underline{x})$. Per farlo approssimiamo $u(\underline{x})$ con un sviluppo di Taylor al primo ordine in un intorno di $\underline{\mu}$:

$$u(\underline{x}) \approx u(\underline{\mu}) + \nabla u|_{x=\mu} \cdot (\underline{x} - \underline{\mu})$$


Dunque i momenti della pdf(y) sono:

- $E[y] = E[u(\underline{\mu})] + \sum_{i=1}^n \frac{\partial}{\partial x_i} u(\underline{\mu}) E[(x_i - \mu_i)] = u(\underline{\mu})$
- $\sigma_y^2 = E[y^2] - E[y]^2 = E[(\underline{x} - \underline{\mu})^T H(u(\underline{x}))|_{x=\mu} (\underline{x} - \underline{\mu})] =$
 $= \sum_{i,j=1}^n \frac{\partial u(\underline{x})}{\partial x_i} \cdot \frac{\partial u(\underline{x})}{\partial x_j} \Big|_{x=\mu} \cdot V_{ij}$

Per un caso bidimensionale l'incertezza su $z = f(x,y)$ è data da:

$$\sigma_z^2 = \left(\frac{\partial f(x,y)}{\partial x} \right)^2 \Big|_{x=\mu} \sigma_x^2 + \left(\frac{\partial f(x,y)}{\partial y} \right)^2 \Big|_{x=\mu} \sigma_y^2 + 2 \frac{\partial f(x,y)}{\partial x} \cdot \frac{\partial f(x,y)}{\partial y} \Big|_{x=\mu} Cov[x,y] \quad (3.13)$$

3.9 Distribuzione di Gauss Multidimensionale

$$f(\underline{x} \mid \underline{\mu}, V) = \frac{1}{(2\pi)^{\frac{n}{2}} \det V^{\frac{1}{2}}} \cdot \exp \left[-\frac{1}{2} < (\underline{x} - \underline{\mu}), V^{-1}(\underline{x} - \underline{\mu}) > \right] \quad (3.14)$$


La gaussiana in due dimensioni in generale ha un profilo ellittico per 1σ . L'angolo d'inclinazione del semiasse maggiore è legato al coefficiente di correlazione:

$$\theta = \frac{2\rho\sigma_x\sigma_y}{\sigma_x^2 - \sigma_y^2} \quad (3.15)$$

Se esplicitiamo l'equazione (3.11) per due variabili si ha:

$$\begin{aligned} f(x, y \mid \mu_x, \mu_y, V) &= \\ &= \frac{1}{(2\pi)\sigma_x\sigma_y\sqrt{1-\rho^2}} \exp \left\{ -\frac{1}{2(1-\rho^2)} \left[\left(\frac{x-\mu_x}{\sigma_x} \right)^2 - \frac{2\rho(x-\mu_x)(y-\mu_y)}{\sigma_x\sigma_y} + \left(\frac{y-\mu_y}{\sigma_y} \right)^2 \right] \right\} \end{aligned}$$

Se il coefficiente di correlazione di Pearson $\rho = 0$ possiamo riscrivere l'equazione precedente come:

$$\begin{aligned} f(x, y \mid \mu_x, \mu_y, V) &= \frac{1}{(2\pi)\sigma_x\sigma_y} \exp \left\{ -\frac{1}{2} \left[\left(\frac{x-\mu_x}{\sigma_x} \right)^2 + \left(\frac{y-\mu_y}{\sigma_y} \right)^2 \right] \right\} = \\ &= G(x, \mu_x, \sigma_x) \cdot G(y, \mu_y, \sigma_y) \end{aligned}$$

In generale è solo vero che due variabili statisticamente indipendenti sono anche decorrelate, nel caso Gaussiano vale anche il viceversa, ovvero se due variabili sono decorrelate allora sono anche statisticamente indipendenti.

3.10 Capitolo 3 - Guida allo studio

1. Come sono definite le distribuzioni di probabilità multi-dimensionali?
2. Che cosa è una distribuzione di probabilità marginale?
3. Che cosa è una distribuzione di probabilità condizionata?
4. Che cosa è una distribuzione di probabilità profilata?
5. Cosa sono la covarianza ed il coefficiente di correlazione fra due variabili, data una distribuzione multi-dimensionale definita nel piano indicizzato dalle due variabili?

CAPITOLO 3. DISTRIBUZIONI DI PROBABILITÀ MULTIDIMENSIONALI

6. Quale è la definizione di variabili indipendenti?
7. Che relazione c'è fra l'indipendenza e la correlazione di due variabili?
8. Come è scritta una Gaussiana a più dimensioni?
9. Che cosa comporta una variazione del coefficiente di correlazione lineare, nella forma della distribuzione Gaussiana?
10. Come si esprime il teorema di Bayes sfruttando la notazione delle distribuzioni di probabilità continue a due variabili?
11. Come si definiscono i momenti di distribuzioni multi-dimensionali?
12. Come si possono ottenere variabili linearmente non correlate, a partire da un insieme di variabili e dalla loro distribuzione di probabilità congiunta?
13. È necessario conoscere la distribuzione di probabilità congiunta, per operare questa decorrelazione?
14. Come si propagano le incertezze, in presenza di cambio di variabili?
15. Che legame c'è fra la probabilità e la statistica?

CAPITOLO 4

Stime di Parametri

4.1 La statistica

La statistica studia il problema di inferire da un campione i parametri e/o i modelli che descrivono la popolazione dalla quale il campione è stato estratto. In particolare possiamo dividerla in due categorie:

- Stima dei parametri, misura di una quantità fisica;
- Test d'ipotesi, ovvero la prova della validità di un modello.

Una funzione dipendente da N misure di un campione $f(x_1, \dots, x_n)$ si chiama **statistica**, essa è una **variabile aleatoria**. Quindi segue una sua distribuzione di probabilità pdf_f derivabile dalla joint-pdf dei campionamenti e dalla forma della funzione f .

Complessivamente si hanno 3 pdf:

- la $pdf_x(x, \theta)$ delle singole misure campionate;
- la $pdf_{set}(x_1, \dots, x_n, \theta)$ dei campionamenti (che è multidimensionale);
- la pdf_f della statistica dei campionamenti (dipende dalla forma funzionale di f).

4.2 Stimatori

Sia data una p.d.f. (probability distribution function), $f(x, \theta)$ di una variabile x aleatoria continua e dipendente da un parametro θ , di cui non

conosciamo il vero valore θ_{true} .

Se si possiede un insieme $\{x_i\}_i^N$ di N misure della variabile x , possiamo chiederci se sia possibile determinare una stima del parametro θ_{true} in funzione di tali misure, $\hat{\theta} = \hat{\theta}(x_1, \dots, x_N)$, le funzioni di questo tipo prendono il nome di **stimatori**. Uno stimatore è una statistica opportunamente scelta. Con **stima** s'intende il valore assunto $\hat{\theta}^*$ dallo stimatore per uno specifico campione.



Figura 4.1: N misure

Poichè lo stimatore $\hat{\theta}$ è dipende da variabili aleatorie è anch'esso una variabile aleatoria e dunque si può parlare di valore medio $E[\hat{\theta}]$ e varianza $V[\hat{\theta}]$ di una particolare stima, oltre ad avere una sua pdf($\hat{\theta}$).

$$\hat{\theta} \pm \sigma_{\theta} \quad (4.1)$$

Di conseguenza un insieme di misure restituirà un solo valore appartenente ad una popolazione ottenuta da campione fatto di misure della variabile aleatoria presa in considerazione.

4.3 Proprietà degli stimatori

Consideriamo un campione di N misure $\{x_i\}_i^N$ vengono definite IID (Independent Identically Distributed) quando sono:

- **indipendenti:** l'esito di una misura non è influenzato dalle misure precedenti;
- **identiche:** Delle misure vengono definite identiche quando tutte quante seguono la stessa distribuzione di probabilità

Nella statistica alle stime si possono associare diverse caratteristiche :

1. **Consistenza:** una stima si dice consistente quando all'aumentare del numero di misure (convergenza probabilistica) si converge al valore vero del parametro. Ossia quando:

$$\lim_{N \rightarrow \infty} \hat{\theta}(x_1, \dots, x_N) = \theta_{true} \quad (4.2)$$




Figura 4.2: Proprietà di consistenza di uno stimatore

2. Biased:

- (a) una stima si dice unbiased o imparziale, se mediamente coincide con il valore vero del parametro, ovvero

$$b_n(\hat{\theta}) = E(\hat{\theta}_n - \theta_{true}) = E(\hat{\theta}_n) - E(\theta_{true}) = 0 \iff E(\hat{\theta}_n) = \theta_{true} \quad (4.3)$$

- (b) Una stima si dice asintoticamente unbiased se $b_n(\hat{\theta}) \rightarrow 0$ per $n \rightarrow \infty$.

Si osserva che $b_n(\hat{\theta})$ è uno stimatore lineare, dunque se $\hat{\theta}$ è stimatore di θ_{true} questo non vuol dire che $\hat{\theta}^2$ è stimatore di θ_{true}^2 .




Figura 4.3: Consistenza e Bias di uno stimatore

3. **Efficienza:** si dice che una stima è più efficiente di un'altra se la sua varianza è inferiore, quindi se mediamente essa è più vicina al valore centrale $E(\hat{\theta})$, che coincide con θ_{true} se la stima è anche imparziale (unbiased).
4. **Varianza:** desideriamo che ripetendo i campionamenti le stime ottenute siano tutte vicine tra loro, ovvero la varianza della $pdf(\hat{\theta})$ sia il più piccola possibile.

4.3.1 Precisione e Accuratezza

Per uno stesso parametro si possono in generale definire tanti stimatori diversi tra loro, ma non tutti hanno le proprietà desiderate. Da notare che non è detto che esista (o sia possibile trovare) uno stimatore che soddisfi contemporaneamente tutte le proprietà richieste.

Esempio

La media delle misure è uno stimatore non distorto.

Dim.

Definito come stimatore la media aritmetica delle misure di un campione IID:

$$\hat{\mu} = \frac{1}{N} \sum x_i$$

si ha che il valore di aspettazione dello stimatore è:

$$E(\hat{\mu}) = E\left(\frac{1}{N} \sum x_i\right) = \frac{1}{N} \sum E(x_i) = \frac{1}{N} \cdot N \cdot \mu_t = \mu_t$$

quindi la media aritmetica è uno stimatore **non distorto** poichè:

$$b_n(\hat{\mu}) = E(\hat{\mu}) - \mu_t = \mu_t - \mu_t = 0$$

Se la pdf(x) delle misure soddisfa le ipotesi del TCL, la pdf($\hat{\mu}$) per $N \rightarrow \infty$ tende a una **gaussiana** con media μ e varianza $\frac{\sigma^2}{N}$ si ha che $\hat{\mu}$ è uno stimatore **consistente**. Poichè $V[\hat{\mu}] = \frac{\sigma^2}{N}$ al crescere del numero di campionamenti la varianza si riduce e dunque le stime ottenute con diversi set di dati sono tutte vicine tra loro.

4.3.2 Incertezze sulle stime

Uno stimatore come ogni altra variabile aleatoria è soggetto a due tipi d'incertezze:

1. **Incertezza sistematica:** nel caso di misure biased esiste una differenza sistematica fra la misura sperimentale ottenuta e il valor vero, ed è uguale per tutte le misure e non è possibile determinarlo essendo una proprietà intrinseca.
2. **Incertezza statistica:** è associata alla precisione, e la si può ridurre aumentando il numero di misure o cambiando l'apparato sperimentale.

$$MSE = E[(\hat{\theta} - \theta_t)^2] = Var(\hat{\theta}) + b_n^2(\hat{\theta}) \quad (4.4)$$

Definisce l'errore quadratico medio e tiene conto sia dell'errore statistico misurato dalla varianza che dell'errore sistematico misurato dal bias.

4.3.3 La Varianza come stimatore

Consideriamo di avere un insieme di N misure, $\{x_i\}_i^N$ di cui conosciamo il valore medio μ della popolazione e di volerne determinare la varianza, poichè essa dipende dalle misure del campione è una variabile aleatoria a sua volta e dunque da un campione definiamo una stima del valore reale del parametro σ_t . Di conseguenza possiamo domandarci le proprietà che tale stimatore possiede.

Definiamo lo stimatore varianza come:

$$\hat{\sigma}_\mu^2(x) = \frac{1}{N} \sum (x_i - \mu)^2 \quad \text{oppure} \quad \hat{\sigma}^2(x) = E(x^2) - E(x)^2$$

Verifichiamo che la varianza sia uno stimatore non distorto ovvero che:

$$E(\hat{\sigma}^2) = \sigma_t$$

Per farlo sfruttiamo la proprietà di linearità del valore atteso.

Dim.

$$\begin{aligned} E(\hat{\sigma}_\mu^2) &= E\left(\frac{1}{N} \sum (x_i - \mu)^2\right) = \frac{1}{N} \sum (E(x_i^2) - 2\mu E(x_i) + \mu^2) = \\ &= \frac{1}{N} \sum (E(x_i^2) - 2\mu E(x_i) + \mu^2) = \frac{1}{N} \sum (E(x_i^2) - \mu^2) = \frac{1}{N} \cdot N \cdot \sigma_t = \sigma_t \end{aligned}$$

Dunque la varianza è uno stimatore non distorto nel caso in cui si conosca il valore medio della popolazione. Raramente si conosce μ della popolazione, dunque consideriamo come stimatore la varianza per un campione di N misure IID.

$$\hat{\sigma}_x^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2$$

Sappiamo che la varianza determina la dispersione di un campione di mi-

sure attorno alla sua media. Ipotizziamo di conoscere il valore medio del campione $\bar{x}$, per costruzione risulta essere il valore più vicino alle misure dell'insieme. La media della popolazione μ non necessariamente coincide con $\bar{x}$ del campione, e dunque può non essere il valore attorno al quale si distribuiscono le misure del campione; infatti nel caso in cui non lo sia al crescere del numero di misure questo può diventare il valore più distante rispetto a $\bar{x}$ stimato dal campione iniziale. Le distanze quadratiche da $\bar{x}$ saranno quindi una sottostima di μ e quindi anche $\hat{\sigma}$ sarà una sottostima di σ_t .

$$\begin{aligned} E[\hat{\sigma}_{\bar{x}}^2] &= \frac{1}{N} \sum E(x_i^2) - E\left[\left(\frac{1}{N} \sum x_i\right)^2\right] = \sigma_t(x)^2 + \mu^2 - \frac{1}{N^2} [\sigma_t^2(\sum x_i) + E(\sum x_i)^2] = \\ &= \sigma_t(x)^2 + \mu^2 - \frac{1}{N^2} [N\sigma_t^2(x) + N^2\mu^2] = \sigma_t^2(x) \left[\frac{N-1}{N} \right] \end{aligned}$$

Di conseguenza la varianza di un campione $\hat{\sigma}_{\bar{x}}$ è uno stimatore distorto, infatti:

$$b_n[\hat{\sigma}_{\bar{x}}^2] = E[\hat{\sigma}_{\bar{x}}^2] - \sigma_t^2 = \sigma_t^2(x) \left[\frac{N-1}{N} \right] - \sigma_t^2$$

ma **asintoticamente non distorto** poichè per $N \rightarrow \infty$ si ha $b_n[\hat{\sigma}_{\bar{x}}^2] \rightarrow 0$.

Notare che quest'ultima definizione è quella operativa per verificare che la varianza sia uno stimatore non ubiased in quanto difficilmente si conosce il valore medio μ della popolazione.

4.3.4 Correzione di Bessel

Si può definire un terzo stimatore, che introduca una correzione a $\hat{\sigma}_{\bar{x}}^2$ tale da cancellare il bias. La correzione del bias è applicabile tutte le volte in cui il bias è precisamente noto. Il nuovo stimatore della varianza sarà dato da:

$$s^2 \equiv \frac{1}{N-1} \sum_{i=1}^N (x_i - \bar{x})^2 \quad (4.5)$$

e prende il nome di **correzione di Bessel**.

CAPITOLO 4. STIME DI PARAMETRI

Lo stimatore è unbiased $E[s^2] = \sigma_t^2$, ma la varianza di tale stimare non può essere determinata per il caso generale

$$V[s^2] = V\left[\frac{1}{N-1} \sum_{i=1}^N (x_i - \bar{x})^2\right] = \frac{1}{(N-1)^2} \sum_{i=1}^N V[(x_i - \bar{x})^2]$$

ma è possibile farlo solo nel caso in cui il campione di misura segue una pdf(x) **Gaussiana**.




Figura 4.4: Misure casuali che seguono una pdf di Gauss tra -1 e 1 in cui $\bar{x}$ del campione iniziale non coincide con il valore medio $\mu = 0$ della popolazione. Dunque $\bar{x}$ non è più il centro del campione al crescere delle misure.

Se riscriviamo lo stimatore s^2 nel seguente modo:

$$s^2 \equiv \frac{1}{N-1} \sum_{i=1}^N (x_i - \bar{x})^2 = \frac{\sigma_t^2}{N-1} \sum_{i=1}^N \frac{(x_i - \bar{x})^2}{\sigma_t^2}$$

possiamo introdurre una variabile aleatoria ausiliaria definita come χ^2 e riscrivere s^2 come:

$$s^2 \equiv \frac{\sigma_t^2}{N-1} \chi^2$$

di conseguenza $V[s^2]$ è legata alla $V[\chi^2]$. Nell'ipotesi in cui le misure raccolte seguano una distribuzione di probabilità Gaussiana la variabile χ^2 segue la distribuzione del chi-quadro. Tale pdf è descritta da un solo parametro definito gradi di libertà e nel nostro caso tale parametro vale $N-1$.

Di conseguenza con questa nuova distribuzione possiamo dimostrare che s^2 è uno stimatore non distorto.

Dim.

$$E[s^2] = E\left[\frac{\sigma_t^2}{N-1} \chi^2\right] = \frac{\sigma_t^2}{N-1} E[\chi^2] = \frac{\sigma_t^2}{N-1} (N-1) = \sigma_t^2$$

La sua varianza è data da:

$$V[s^2] = V\left[\frac{\sigma_t^4}{(N-1)^2} \chi^2\right] = \frac{\sigma_t^4}{(N-1)^2} V[\chi^2] = \frac{2\sigma_t^4}{(N-1)^2}$$

4.4 Intervallo di confidenza


Si è costruito uno stimatore $\hat{\theta}$ per un parametro θ che è una variabile aleatoria di conseguenza esiste una distribuzione pdf($\hat{\theta}$) che è caratterizzata da una media $E[\hat{\theta}]$ e una varianza $V[\hat{\theta}]$. La **stima** è il valore che lo stimatore assume in corrispondenza di un campione di dati e lo definiamo $\hat{\theta}^*$.

L'**intervallo di confidenza** è solitamente indicato come:

$$\hat{\theta}^* \pm \sigma \quad \text{oppure} \quad \hat{\theta}^* \begin{matrix} +\sigma_1 \\ -\sigma_1 \end{matrix} \quad (4.6)$$

la seconda notazione viene usata quando l'intervallo è asimmetrico.

In generale il risultato della stima è un intervallo $[a, b]$, poichè è una variabile aleatoria si ha che gli estremanti sono variabili aleatorie e dunque per diversi campioni si hanno diversi intervalli di confidenza. A ciascun intervallo viene associata una probabilità (**livello di confidenza**) che misura quanto è buona la stima del valore vero.



$$P(\theta_t \in [a, b])$$

dove essa rappresenta la frazione delle volte in cui ripetendo l'esperimento, la stima restituisce un intervallo che contiene il valore vero.

In generale si vuole trovare un metodo che individui un intervallo $[a, b]$ tale per cui la probabilità che $\theta_t \in [a, b]$ sia pari a un certo valore β detto **livello di confidenza**. Un intervallo di confidenza così definito prende il nome di **intervallo di condifenza di Neyman**. Un intervallo particolare è quello dato da $[\hat{\theta}^* - \sigma, \hat{\theta}^* + \sigma]$ e si definisce **intervallo centrale**.

4.5 Capitolo 4 - Guida allo studio

1. Che cosa è una statistica?
2. Che cosa è uno stimatore?
3. Che cosa è uno stimatore consistente?
4. Che cosa è la distorsione - o bias - di uno stimatore?

5. Che proprietà hanno la media campionaria e la varianza di un campione, come stimatori di valore di aspettazione e varianza della popolazione?
6. Che legame c'è fra la varianza di un campione di misure e la distribuzione del chiquadro?
7. Quale è la varianza dello stimatore della media e della varianza di una misura?
8. Che cosa è un intervallo di confidenza?
9. Come si interpreta statisticamente?

CAPITOLO 5

Maximum Likelihood e Minimi Quadrati

5.1 La Verosomiglianza - Likelihood

Date N misure $\{x_i\}_i^N$ IID la funzione di probabilità congiunta (joint-pdf) è definita dal prodotto delle singole distribuzioni di probabilità (poiché indipendenti tra loro):

$$pdf_{set}(x_1, \dots, x_N, \underline{\theta}_t) = \prod_i^N pdf_x(x_i, \underline{\theta}_t)$$

essa rappresenta la densità di probabilità del campione di misure rispetto a un parametro $\underline{\theta}_t$ che è conosciuto a priori, ed è una funzione definita su uno spazio N -dimensionale.

Se si sostituisce al valore vero $\underline{\theta}_t$ il generico valore $\hat{\underline{\theta}}$ stimato dalle N misure e se esse vengono considerate non più variabili casuali, ma costanti che sono state determinate dalle operazioni di misura, la precedente funzione prende il nome di *funzione di verosomiglianza* o **likelihood**.

$$L(\hat{\underline{\theta}}) = \prod_i^N pdf_x(x_i, \hat{\underline{\theta}})$$

al variare di $\hat{\underline{\theta}}$ tale funzione ci descrive l'evoluzione della densità di probabilità del medesimo set di misure rispetto a pdf differenti tra loro.

Esempio

Una pdf Gaussiana é descritta dai parametri μ e σ^2 cambiandone i valori definiamo differenti pdf e di conseguenza mantenendo le misure fissate avremo diversi valori della probabilità associata al campione.




Figura 5.1: pdf Gaussian per un medesimo set di misure al variare dei parametri di media e varianza.

Quando definiamo una $pdf(x, \theta)$ senza conoscere θ si descrive un fascio di distribuzioni di probabilità e dunque un'infinità di modelli diversi. Cambiando la varianza di una distribuzione di cambia anche la funzione di likelihood.


È possibile definire anche la **loglikelihood** ovvero:

$$l(\underline{\theta}) = \log(L(\underline{x}, \underline{\theta})) = \log\left(\prod_i^N pdf_x(x_i, \underline{\theta})\right) = \sum_i^N \log(pdf_x(x_i, \underline{\theta}))$$


5.2 Comportamento della likelihood

Raccolte delle misure $\{x_i\}_i^N$ IID, la funzione di likelihood $L(\theta)$ restituisce la probabilità che si aveva di raccogliere tale campione assunta la conoscenza del parametro θ (che per comodità in questo capitolo assumiamo in una sola dimensione).

Se la $L(\theta)$ è all'incirca piatta vuol dire che si ha la stessa probabilità di ottenere un campionamento $\{x_1, \dots, x_N\}$ per ogni valore di θ , ciò significa che i campionamenti non forniscono molte informazioni sul parametro θ .



Se la $L(\theta)$ ha la forma di una campana e si conosce θ_t vuol dire che si avrà una probabilità:



- Alta se il θ_t è nell'area arancione in figura
- bassa se θ_t è nella regione verde
- massima se θ_t coincide con il massimo della funzione di likelihood

che il campione ottenuto fornisca informazione per una stima precisa

del valore θ_t . Dunque i campionamenti forniscono informazioni su θ . Più è stretta la campana e più piccolo è il range dei valori che massimizzano la probabilità associata al campione raccolto. La larghezza della campana è legata all'incertezza con cui è possibile determinare il valore vero di θ .

5.3 Minimum Variance Bound

La funzione di likelihood $L(\theta)$ può essere utilizzata per misurare l'informazione che i campionamenti contengono relativamente al parametro θ che descrive il modello. L'informazione così ottenuta consente di valutare la minima varianza raggiungibile di uno stimatore $\hat{\theta}$, ovvero dato un insieme di misure e un modello esiste un limite inferiore alla varianza raggiungibile.

5.3.1 Informazione di Fischer

Vogliamo costruire una metrica $I(\theta)$ che fornisca l'ammontare d'informazione contenuta in una variabile casuale osservabile x , relativamente a un parametro non osservabile θ , da cui dipende la pdf(x, θ). Tale funzione prende il nome d'**informazione di Fischer**.

$$I(\theta) = E\left[\left(\frac{\partial}{\partial \theta} \log(L(\theta))\right)^2\right] = -E\left[\frac{\partial^2}{\partial \theta^2} \log(L(\theta))\right]$$

essa gode delle seguenti proprietà:

- Associa un valore nullo se i dati sono irrilevanti per la stima di θ .
- Aumenta al crescere della dimensione del campione (purchè i dati siano rilevanti per la stima di θ).
- È legata alla precisione della stima (Teorema di Raó-Cramér): se l'informazione aumenta la varianza minima raggiungibile da uno stimatore $\hat{\theta}$ diminuisce.

Più i valori assunti dalla likelihood risultano essere sparpagliati peggiore è l'informazione che si ha a disposizione e dunque la precisione di stima di uno stimatore ne risentirà in egual modo. Viceversa più i valori risultano essere raggruppati in una certa regione di spazio e migliore sarà la precisione con cui si ottiene lo stimatore.

5.3.2 Teorema di Rao - Cramér

Per uno stimatore $\hat{\theta}(x)$ consistente, bias $b_n(\hat{\theta})$, $V[\hat{\theta}] < \infty$ e non dipendente da x , definito su un dominio Ω_θ si ha che il **MVB (Minimum Variance**

Bound) definisce una relazione tra la varianza di un qualsiasi stimato $\hat{\theta}$ e la likelihood $L(\underline{X}, \theta)$ nel seguente modo:

$$V[\hat{\theta}] \geq \frac{(1 - \frac{\partial}{\partial \theta} b_n(\theta))^2}{E[(\frac{\partial}{\partial \theta} \log(L(\theta)))^2]} = V[\hat{\theta}]_{min} \quad (5.1)$$

Al numeratore si ha una quantità che dipende dallo specifico stimatore $\hat{\theta}$, ma solo se questo è biased, mentre a denominatore si ha l'informazione di Fischer, dunque una quantità che non dipende dallo specifico stimatore ma solo da modello e dati.

Diciamo che uno stimatore è **efficiente** se la grandezza:

$$\xi(\hat{\theta}) = \frac{V[\hat{\theta}]_{min}}{V[\hat{\theta}]} = 1 \quad (5.2)$$

5.4 Maximum Likelihood

Considerato un campione di N misure IID, si definiscono stimatori di **Maximum Likelihood (ML)** dei parametri quei valori che massimizzano la funzione di likelihood. Data una likelihood differenziabile rispetto $\underline{\theta}$ e il cui punto di massimo non è ai margini del range dei parametri, gli stimatori $\hat{\underline{\theta}}$ sono dati dalla soluzione delle equazioni differenziali:

$$\frac{\partial L}{\partial \theta_i} = 0 \quad i = 1, \dots, N \quad (5.3)$$

Se esiste più di un massimo, viene considerato il maggiore.

Con questa definizione di ML si considera il valore dello stimatore in corrispondenza del quale la probabilità associata al campionamento è la massima possibile.

Le proprietà degli stimatori ottenute con il metodo di ML valgono asintoticamente, ovvero con un numero sufficientemente elevato di misure. Alcune **proprietà notevoli** sono:

1. Consistente

2. Asintoticamente efficiente
3. Asintoticamente non distorto
4. Proprietà d'invarianza: $\hat{\theta}_{ML}$ stimatore di $\theta_t \Rightarrow g(\hat{\theta}_{ML})$ è stimatore di $g(\theta_t)$.

Esempio proprietà d'invarianza

Consideriamo la distribuzione esponenziale $f(x, \tau) = \frac{1}{\tau} e^{-\frac{x}{\tau}}$ e si abbiano N misure IID la likelihood rispetto a τ è $L(\tau) = \prod_i^N \frac{1}{\tau} e^{-\frac{t_i}{\tau}}$.

Applichiamo il metodo di ML alla loglikelihood di τ , dunque si ha che:

$$\sum_i^N \left(-\frac{1}{\tau} + \frac{t_i}{\tau^2}\right) = 0 \iff N = \sum_i^N \frac{t_i}{\tau} \iff \tau_{ML} = \frac{1}{N} \sum_i^N t_i$$

Posto $\lambda(\tau) = \frac{1}{\tau}$ possiamo riscrivere la pdf come $f(x, \lambda) = \lambda e^{-\lambda t}$ data la sostituzione vogliamo verificare che $\lambda(\tau_{ML}) = \frac{1}{\tau_{ML}}$.

Dim.

$$\frac{\partial l}{\partial \theta} = 0 \iff \sum_i^N \left(\frac{1}{\lambda} - t_i\right) = 0 \iff \frac{N}{\lambda} = \sum_i^N t_i \iff \lambda = \frac{1}{\tau}$$

Se si dimostra che $\hat{\tau}$ è uno stimatore non distorto, è anche vero che $\hat{\lambda}$ è anch'esso non distorto ?

Poichè la relazione $\hat{\lambda}(\hat{\tau})$ può essere non lineare non è detto che anche $\hat{\lambda}$ sia non distorto.

Si può dimostrare che $\hat{\lambda}$ è uno stimatore distorto di λ e dunque solo asintoticamente non lo è.

5.5 Varianza dello stimatore di ML - Metodo Grafico

Espandiamo fino al secondo ordine con un polinomio di Taylor la loglikelihood in un'intorno del parametro $\hat{\theta}$ ottenuto con il metodo di ML.

$$\log(L(\theta)) \approx \log(L(\hat{\theta})) + \frac{1}{2} \frac{d^2}{d\theta^2} (\log(L(\theta)))|_{\theta=\hat{\theta}} (\theta - \hat{\theta})^2 \quad (5.4)$$

Se assumiamo che lo stimatore sia unbiased (il che per le proprietà precedenti asintoticamente può esserlo) ed efficiente si ha dal teorema di Rao-Cramer che il secondo addendo è equivalente a:

$$\frac{d^2}{d\theta^2} \log(L(\theta))|_{\theta=\hat{\theta}} = -\frac{1}{\sigma_{\hat{\theta}_{ML}}}$$

E dunque possiamo riscrivere l'equazione (5.4) come:

$$\log(L(\theta)) \approx \log(L(\hat{\theta})) - \frac{1}{2\sigma_{\hat{\theta}_{ML}}} (\theta - \hat{\theta})^2 \quad (5.5)$$

Consideriamo un cambio di variabile da $\hat{\theta}$ a $\hat{\theta} \pm \sigma_{\hat{\theta}}$ dunque possiamo riscrivere la (8.7) come:

$$\log(L(\hat{\theta} \pm \sigma_{\hat{\theta}})) = \log(L(\hat{\theta})) - \frac{1}{2} \quad (5.6)$$

dunque da tale cambio di variabile si ha che la loglikelihood diminuisce della metà del suo valore di massimo. Si può dimostrare che la funzione di loglikelihood diventa una parabola (e la funzione di likelihood diventa una Gaussiana) per valori grandi del campione. Anche se la $\log(L)$ non è parabolica si può utilizzare l'equazione (5.6) come la definizione di errore statistico. Determinando i punti d'intersezione con quanto definito in (5.6) si ottiene una stima della varianza dello stimatore $\hat{\theta}$ usando il metodo di ML.

Con un numero finito di misure $l(\theta)$ non è simmetrico e al crescere del numero di misure la forma funzionale assume un aspetto parabolico. Per simmetria la likelihood $L(\theta)$ diventa una Gaussiana.




Figura 5.2: funzione di loglikelihood, stima della varianza




Figura 5.3: likelihood per un campione di 800 misure

5.6 Extended likelihood

Consideriamo una variabile aleatoria x distribuita secondo una pdf $f(x, \underline{\theta})$, dove i parametri $\underline{\theta}$ non li conosciamo e ipotizziamo di avere un campione di N misure $\{x_1, \dots, x_N\}$. Spesso si ha che il numero di osservazioni n del campione è una variabile aleatoria che segue una pdf Poissoniana con frequenza media λ . Il risultato di un'esperimento può essere definito dalla variabile n (che è la dimensione del campione) e dalle n misure raccolte $\{x_1, \dots, x_n\}$.

Dunque possiamo definire la likelihood dei parametri $\underline{\theta}$, dato un numero di

eventi medio λ rispetto ad un campione di n misure.

$$L(\lambda, \theta) = \frac{\lambda^{-n}}{n!} e^{-\lambda} \prod_{i=1}^n f(x_i, \underline{\theta}) = \frac{e^{-\lambda}}{n!} \prod_{i=1}^n \lambda_i f(x_i, \underline{\theta}) \quad (5.7)$$

Tale funzione prende il nome di **extended likelihood**.

5.6.1 Applicazioni della Extended Likelihood

É utile applicare il metodo della extended likelihood quando la $\text{pdf}(x, \underline{\theta})$ può essere espressa come combinazione lineare di funzioni elementari indipendente tra loro:

$$\text{pdf}(x, \underline{\theta}) = \sum_{k=1}^N \theta_k p_k(x) \quad \text{dove} \quad \int p_k(x) = 1$$

Tale situazione si verifica quando la variabile aleatoria che si osserva é esprimibile come combinazione di segnali, dove ciascuno di essi é descritto da una pdf $p_k(x)$ e probabilità relative θ_k sconosciute.

Un esempio sperimentale é dato da un fascio di particelle cariche la cui perdita d'energia viene rilevata da un rivelatore di volume.

5.7 Varianza di uno stimatore per più parametri

La varianza di $V[\hat{\theta}]$ di un vettore di parametri è definita dalla matrice di covarianza dove le sue componenti sono date da:

$$V_{ij} = \left[-\frac{\partial^2}{\partial \theta_i \partial \theta_j} \log(L(\hat{\theta})) \right]^{-1} \quad \text{per} \quad i, j = 1, \dots, n \quad (5.8)$$

dove i termini per $i \neq j$ sono dati da $\text{Cov}[\theta_i, \theta_j]$.


5.8 Metodo dei minimi quadrati

Si parte da un modello $y = f(x, \underline{\theta})$ che definisce una relazione tra due grandezze fisiche x ed y e che dipende da N parametri $\underline{\theta}$, ipotizziamo di avere un campione di misure formato da punti $\{(x_i, y_i)\}_i^N$ ciascuno di essi segue una $\text{pdf}(x)$ e una $\text{pdf}(y)$ di conseguenza sono variabili aleatorie che

hanno una loro incertezza σ_x e σ_y . Vogliamo trovare un metodo che ci permetta di stimare i parametri ignoti partendo dai dati sperimentali. Tale metodo prende il nome di **minimi quadrati**. Per semplicità consideriamo il caso il cui l'incertezza sulle misure x sia trascurabile.

5.8.1 Funzionale Q^2

Partiamo considerando solo la variabile aleatoria x e ci domandiamo per quali valori del campione, si minimizza la distanza dalla media della popolazione $E[x] = \mu$; per rispondere a tale domanda definiamo la misura della distanza definendo un funzionale:



$$Q^2(\{x_i\}_1^N, \mu) = \frac{1}{N} \sum_{i=1}^N \frac{(x_i - \mu)^2}{\sigma_i^2} \quad (5.9)$$

Dunque ciascuna distanza è normalizzata alla larghezza della $pdf(x_i)$ e quindi tiene conto delle fluttuazioni statistiche di quel determinato campionamento.

Per determinare il parametro cerchiamo quel valore $\hat{\mu}_{MQ}$ per cui Q^2 ammette un minimo assoluto nello spazio dei parametri (che nel nostro caso ha dimensione 1):

$$\frac{d}{d\mu} Q^2(\{x_i\}_1^N, \mu) = 0 \quad (5.10)$$

5.8.2 Valore di aspettazione di $\hat{\mu}_{MQ}$

Derivando la funzione di Q^2 si ha:

$$\frac{d}{d\mu} Q^2 = -2 \sum_{i=1}^N \frac{(x_i - \hat{\mu}_{MQ})}{\sigma_i^2} = 0 \iff \hat{\mu}_{MQ} = \frac{\sum_{i=1}^N \frac{x_i}{\sigma_i^2}}{\sum_{i=1}^N \frac{1}{\sigma_i^2}} = \bar{x}$$

dunque per un campione di N misure la stima del valore atteso della popolazione coincide con la media aritmetica pesata del campione.

5.8.3 Varianza dello stimatore $\hat{\mu}_{MQ}$

Consideriamo $\hat{\mu}_{MQ} = \phi(x_1, \dots, x_N)$ e che il campione sia costituito da misure statisticamente indipendenti rispetto la variabile aleatoria x , la varianza dello stimatore sarà data da:

$$V[\hat{\mu}_{MQ}] = \sum_{i=1}^N \left(\frac{\partial \phi}{\partial x_i} \right)^2 \sigma_i^2 = \left[\sum_{i=1}^N \frac{1}{\sigma_i^2} \right]^{-2} \sum_{i=1}^N \left(\frac{1}{\sigma_i^2} \right)^2 \sigma_i^2 = \frac{1}{\sum_{i=1}^N \frac{1}{\sigma_i^2}} < \sigma_i^2 \quad \forall i$$

L'incertezza è dominata dalle misure con le σ_i più piccole.

5.9 Varianza di un stimatore usando i MQ - Metodo grafico

Con il metodo di maximum likelihood si sono cercati i valori dei parametri che rendevano massima la probabilità, dato un modello, di osservare i dati campionati. Con il metodo dei minimi quadrati invece si cerca il valore dei parametri che rende minima la distanza tra i dati campionati e il modello. Quando le $pdf(x_i)$ sono Gaussiane i due stimatori coincidono.

$$L(\hat{\theta}) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi}\sigma_i} \exp \left[-\frac{(x_i - \hat{\theta})^2}{2\sigma_i^2} \right] = cost \cdot e^{-\frac{Q^2}{2}}$$

se passiamo alla loglikelihood

$$\log(L(\hat{\theta})) = \log(cost) - \frac{Q^2(\hat{\theta})}{2}$$

Stimando $\hat{\theta}$ con il metodo di Maximum Likelihood si ha

$$\frac{\partial \log(L(\hat{\theta}))}{\partial \hat{\theta}} = -\frac{1}{2} \frac{\partial Q^2(\hat{\theta})}{\partial \hat{\theta}} \quad (5.11)$$

CAPITOLO 5. MAXIMUM LIKELIHOOD E MINIMI QUADRATI

Quando le misure seguono una pdf Gaussiana (e quindi anche gli errori ϵ e lo stimatore $\hat{\theta}$ è efficiente e non distorto sappiamo che il MVB coincide con la varianza dello stimatore ottenuto con il metodo di ML.

$$V[\hat{\theta}_{ML}] = -\frac{1}{\left. \frac{\partial^2 \log(L(\theta))}{\partial \theta^2} \right|_{\theta=\hat{\theta}_{ML}}} \quad (5.12)$$

Dalla relazione (5.11) possiamo riscrivere l'uguaglianza (5.12) come:

$$V[\hat{\theta}_{MQ}] = \frac{2}{\left. \frac{\partial^2 Q^2(\theta)}{\partial \theta^2} \right|_{\theta=\hat{\theta}_{MQ}}} \quad (5.13)$$


Sviluppando con Taylor al secondo ordine la funzione Q^2 in un intorno di $\hat{\theta}_{MQ}$ si ha:

$$Q^2(\theta) \approx Q^2(\hat{\theta}_{MQ}) + \frac{1}{2} \frac{d^2 Q^2(\theta)}{d\theta^2} \Big|_{\theta=\hat{\theta}_{MQ}} (\theta - \hat{\theta}_{MQ})^2 = Q^2(\hat{\theta}_{MQ}) + \frac{(\theta - \hat{\theta}_{MQ})^2}{V[\theta]}$$

Effettuando un cambio di coordinate $\theta = \hat{\theta}_{MQ} \pm \sigma_{\hat{\theta}}$ si ha:

$$Q^2(\hat{\theta}_{MQ} \pm \sigma_{\hat{\theta}}) = Q^2(\hat{\theta}_{MQ}) + 1$$

Dunque considerando graficamente l'intersezione con $Q^2(\theta)$ si determinano $\hat{\theta}_{MQ} \pm \sigma_{\hat{\theta}}$. Poichè per ipotesi le misure $\{x_i\}_i^N$ seguono una distribuzione di probabilità Gaussiana e sono IID si ha che $Q^2(\theta)$ segue la distribuzione di probabilità del chi quadro $\chi^2(N-k)$ per $E[Q^2] = N-k$ gradi di libertà. Se questo non avviene è perchè:



- si è avuta una fluttuazione statistica sfavorevole
- il modello non descrive i dati

- il modello è corretto, ma i dati sono stati raccolti in modo errato
- il modello è corretto, ma le incertezze attribuite ai dati sono sbagliate (sono sopra o sottovalutate).

5.10 Modelli lineari nei parametri - Regressione Lineare

Un modello si definisce **lineare** se due grandezza fisiche x ed y sono legate da una relazione lineare rispetto a parametr $\underline{\theta}$.

$$y_0^i = \sum_{j=1}^N \theta_j h_j(x_i) \quad (5.14)$$

Assumiamo che l'incerteza sulla variabile x sia influente, mentre y è una variabile aleatoria le cui misure sono IID con varianza $V[y_i] = \sigma_i^2$. Definiamo una variabile aleatoria ausiliaria ϵ che possiede la stessa distribuzione di probabilità di y . Riscriviamo (5.15) come:

$$y_i = \sum_{j=1}^N \theta_j h_j(x_i) + \epsilon_i \quad (5.15)$$

Assumiamo che per le ϵ valgano le seguenti proprietà:

$$E[\epsilon_i] = 0 \quad V[\epsilon_i] = V[y_i] = \sigma_i^2$$

In questo modo la pdf(y) coincide con la pdf(ϵ). La variabile ϵ rappresenta l'errore statistico sulla misura, mentre le y_0 sono il valore vero della misura restituito dal modello.

Applichiamo il metodo dei minimi quadrati, andando a stimare quei valori dei parametri $\underline{\theta}$ che minimizzano la distanza tra il valore vero restituito dal modello lineare e i dati campionati sperimentalmente, pesando gli scarti quadratici rispetto la varianza delle distribuzioni di probabilità delle singole y_i .

Per farlo utilizziamo il funzionale Q^2 riscrivendolo come:

$$Q^2 = \sum_{i=1}^N \frac{(y_i - y_0(x_i, \theta))^2}{\sigma_i^2} = \sum_{i=1}^N \frac{(y_i - \sum_{j=1}^N \theta_j h_j(x_i))^2}{\sigma_i^2} = \sum_{i=1}^N \frac{\epsilon_i}{\sigma_i^2} \quad (5.16)$$




Figura 5.4: $\psi(x_3)$ rappresenta il valore vero della misura rispetto al modello, mentre y_3 il dato campionato su cui è presente un errore statistico.

5.10.1 Stime dei parametri

Per un vettore di parametri $\underline{\theta}$ di dimensione N , avremo un sistema di K equazioni:

$$\nabla Q^2(\underline{x}, \underline{\theta}) = \begin{cases} \frac{\partial Q^2}{\partial \theta_1} = 0 \\ \vdots \\ \frac{\partial Q^2}{\partial \theta_n} = 0 \end{cases} \quad (5.17)$$

Per una singola riga si ha:

$$\frac{\partial Q^2}{\partial \theta_j} = \sum_{i=1}^N \frac{-2}{\sigma_i^2} \left(\frac{y_i - \sum_{j=1}^N \theta_j h_j(x_i)}{\sigma_i} \right)^2 h_j(x_i) = 0 \quad \forall i = 1, \dots, N \quad (5.18)$$

Per comodità di esposizione riscriviamo l'espressione (5.16) in forma vetto-

riale:

$$\underline{y} = H\underline{\theta} + \underline{\epsilon} \quad (5.19)$$

ed essendo una modello a più parametri si ha la matrice di covarianza $V[\epsilon]$, possiamo considerare la matrice in funzione di ϵ poichè $V[y]$ e $V[\epsilon]$ sono legate da una traslazione rigida e dunque risultano essere identiche. In generale tale matrice non è diagonale, ma poichè si è assunto che le misure siano IID la matrice è diagonale.

$$V[\epsilon] = \begin{bmatrix} \sigma_i^2 & \dots\dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & \sigma_n^2 \end{bmatrix}$$

Riscrivendo $Q^2 = \underline{\epsilon}^T V^{-1} \underline{\epsilon}$ in forma matriciale e risolvendo il sistema (5.19) si stimano i parametri come:

$$\hat{\underline{\theta}}_{MQ} = (H^T V^{-1} H)^{-1} \cdot H^T V^{-1} \underline{y} \quad (5.20)$$

dove $V(\hat{\underline{\theta}}) = (H^T V^{-1} H)^{-1}$ dove nella matrice H è contenuta l'informazione delle misure.

Resta da verificare che lo stimatore sia non distorto ovvero $E(\hat{\underline{\theta}}) = \underline{\theta}_t$:

$$E[\hat{\underline{\theta}}_{MQ}] = (H^T V^{-1} H)^{-1} \cdot H^T V^{-1} E[\underline{y}] = (H^T V^{-1} H)^{-1} \cdot (H^T V^{-1} H) \underline{\theta}_t$$

dove:

$$E[\underline{y}] = E[H\hat{\underline{\theta}} + \underline{\epsilon}] = E[H\hat{\underline{\theta}}] + E[\underline{\epsilon}] = HE[\hat{\underline{\theta}}] = H\underline{\theta}_t$$

duque lo stimatore ottenuto è non distorto.

A differenza del metodo di ML che gode di buone proprietà asintoticamente si ha che quello dei MQ le ha per un numero finito di misure.

5.11 Sovrastima degli errori

Ipotizziamo che le incertezze siano sovrastimate di un fatto α ovvero $\sigma_i^* = \alpha \cdot \sigma_i$, di conseguenza possiamo riscrivere la matrice di covarianza come:

$$W[y^*] = \alpha^2 \cdot \begin{bmatrix} \sigma_i^2 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \sigma_n^2 \end{bmatrix} = \alpha^2 \cdot V[y]$$

Se sostituiamo tale ipotesi all'interno dell'equazione (5.21) si ha:

$$\begin{aligned} \hat{\underline{\theta}} &= (H^T W^{-1} H)^{-1} \cdot H^T W^{-1} \underline{y} = \alpha^2 \cdot \frac{1}{\alpha^2} \cdot (H^T V^{-1} H)^{-1} \cdot H^T V^{-1} \underline{y} = (5.21) \\ &= (H^T V^{-1} H)^{-1} \cdot H^T V^{-1} \underline{y} \end{aligned}$$

dunque la stima del parametro $\hat{\underline{\theta}}_{MQ}$ rimane invariata anche se si sono sovrastimate le incertezze. Quella che cambia è la varianza del parametro stimato infatti:

$$V[\hat{\underline{\theta}}_{MQ}] = (H^T W^{-1} H)^{-1} = \alpha^2 (H^T V^{-1} H)^{-1} \quad (5.22)$$

e dunque viene sovrastimata di un fattore α^2 .

5.11.1 Relazione tra il numero di parametri e il campione

Se si hanno K parametri e campione di dimensione N dove K=N si ha che:

- il sistema ammette soluzione, e si ha una curva che passa per tutti i punti;
- se il sistema non ammette soluzione allora i dati falsificano il modello.

5.11.2 Incertezze sulla variabile indipendente

Nel caso in cui il modello sia lineare rispetto ai parametri, per esempio una retta $y(x, a, b) = a + bx$ e siano presenti delle incertezze sulla variabile indipendente x, si propaga l'errore sulle y_i l'errore di σ_{x_i} ottenendo un errore

complessivo $\sigma_i^2 = \sigma_{y_i}^2 + b\sigma_{x_i}^2$ e dunque il funzionale Q^2 si riscrive come:

$$Q^2 = \frac{1}{N} \sum_{i=1}^N \frac{(y_i - y)^2}{\sigma_{y_i}^2 + b\sigma_{x_i}^2} \quad (5.23)$$

5.11.3 Stima del fattore di sovrastima α

Ipotizziamo che gli $\underline{\epsilon}$ seguano una distribuzione di probabilità Gaussiana e di avere N misure indipendenti allora il funzione Q^2 definito come l'ultima uguaglianza della (5.17) è segue la distribuzione di $\chi^2(N-K)$ per $N-K$ gradi di libertà dove K è il numero di parametri da stimare. In forma matriciale possiamo riscriverlo rispetto alla matrice di sovrastima W come:

$$\hat{Q}^2 = \epsilon^T W^{-1} \epsilon = \frac{1}{\alpha^2} \cdot \epsilon^T W^{-1} \epsilon = \alpha^{-2} \cdot Q^2 \quad (5.24)$$

Vogliamo determinare α^2 affinché $\hat{Q}_{min}^2 = E[\hat{Q}^2] = N - K$ e dunque:

$$\alpha^2 = \frac{\hat{Q}_{min}^2}{N - K} \quad (5.25)$$

Il fattore di scala così determinato non costituisce la sovrastima "reale" di cui si sono sbagliate le misure, poichè $\hat{Q}_{min}^2(\underline{x}, \hat{\underline{\theta}}_{MQ})$ per $\hat{\underline{\theta}}_{MQ}$ fissato è anch'esso una variabile aleatoria che segue la distribuzione di $\chi^2(N-K)$ di conseguenza la (5.25) stima un solo valore rispetto al campione a disposizione, ma α^2 è una variabile aleatoria che segue la medesima distribuzione di $\hat{Q}_{min}^2(\underline{x}, \hat{\underline{\theta}}_{MQ})$ e dunque per determinarlo bisogna ricostruire la distribuzione del χ^2 .



5.12 Teorema di Gauss-Markov

Si consideri un insieme di variabili aleatorie statisticamente indipendenti $\{(x_i, y_i)\}_i^N$ tali che sono legate tra loro da una relazione lineare rispetto ai parametri $y_i = \psi(x_i, \underline{\theta}) + \epsilon_i$ dove $E[\epsilon_i] = 0$ e $V[\epsilon_i]$ finita $\forall i$ (proprietà di

omoschedasticità) ed indipendente dai parametri $\underline{\theta}$ e dalle misure $y_i \Rightarrow$ si ha che lo stimatore $\hat{\underline{\theta}}$ ottenuto con il metodo dei minimi quadrati è non distorto e ha varianza minima fra tutti gli stimatori lineari.


Osservazioni

- ϵ_i non è necessario che siano distribuite secondo una Gaussiana
- il teorema non ci dice che si è trovato lo stimatore più **efficiente** fra tutti gli stimatori possibili, ma sicuramente quello più efficiente tra quelli lineari.

È possibile trovare uno stimatore più efficiente per i parametri $\underline{\theta}$ però dovremmo determinarlo con una funzione non lineare e ammesso che questa esista non è garantito che lo stimatore ottenuto sia non distorto.

Gli stimatori descritti dal teorema di Gauss-Markov vengono definiti **B.L.U.E** (**B**est **L**inear **U**nbiased **E**stimator).

5.13 Interpolazione ed Estrapolazione



Assumendo che i parametri $\underline{\theta}$ siano già stati determinati. **L'interpolazione** è la determinazione del valore di y mediante la funzione $\psi(x, \underline{\theta})$ per una misura x contenuta all'interno del range delle misure, ovvero l'intervallo

contenente i dati del campione. Si definisce **estrapolazione** il valore di y per qualsiasi altro valore di x non compreso all'interno del range delle misure definito sperimentalmente. Per un valore ottenuto da una retta di regressione lineare, l'errore è legato all'incertezza nella stima dei parametri di $\underline{\theta}$. Di conseguenza:

$$V[y]_i = \nabla \psi(x, \underline{\theta})^T \cdot Cov[\hat{\underline{\theta}}_{MQ}] \cdot \nabla \psi(x, \underline{\theta}) \quad (5.26)$$

Per esempio in un caso a due parametri si avrà:

$$V[y]_i = \begin{bmatrix} \frac{\partial \psi}{\partial \theta_1} & \frac{\partial \psi}{\partial \theta_2} \end{bmatrix} \cdot \begin{bmatrix} \sigma_{\theta_1}^2 & Cov(\theta_1, \theta_2) \\ Cov(\theta_2, \theta_1) & \sigma_{\theta_2}^2 \end{bmatrix} \cdot \begin{bmatrix} \frac{\partial \psi}{\partial \theta_1} \\ \frac{\partial \psi}{\partial \theta_2} \end{bmatrix}$$

che coincide con la formula di propagazione degli errori presente al capitolo 3. In generale l'errore aumenta allontanandosi dalla regione di campionamento (quindi quando si passa dall'interpolazione all'estrapolazione).

Esempio di fit lineare

Consideriamo di avere un set di misure $\{(x_i, y_i)\}_i^N$ IID con incertezza σ_{y_i} sulla variabile aleatoria y , e che il modello è quello di una retta $y = a+bx$, stimiamo i parametri a e b usando il metodo dei minimi quadrati. Avremo che:

$$\vec{\theta} = \begin{bmatrix} a \\ b \end{bmatrix} \quad \vec{h} = \begin{bmatrix} 1 \\ x \end{bmatrix}$$

e poichè le misure sono indipendenti tra loro, la matrice di covarianza è diagonale. Applicando il metodo dei MQ si stimano:

$$\hat{a} = \frac{1}{\sum_{i=1}^N \frac{1}{\sigma_i^2}} \sum_{i=1}^N \frac{y_i - \hat{b}x_i}{\sigma_i^2} = \bar{y} - \hat{b}\bar{x}$$

$$\hat{b} = \frac{1}{\sum_{i=1}^N \left(\frac{x_i}{\sigma_i}\right)^2} \sum_{i=1}^N \frac{y_i x_i - \hat{a}x_i}{\sigma_i^2} = \frac{\overline{xy} - \bar{x}\bar{y}}{\overline{x^2} - \bar{x}^2}$$

e le incertezze associate alle stime sono date dalla matrice di covarianza associate ai parametri:

$$V[\hat{\theta}] = \begin{bmatrix} \sigma_a^2 & Cov[a, b] \\ Cov[b, a] & \sigma_b^2 \end{bmatrix} = \frac{\sigma^2}{N(\overline{x^2} - \bar{x}^2)} \cdot \begin{bmatrix} \overline{x^2} & -\bar{x} \\ -\bar{x} & 1 \end{bmatrix}$$


I termini in viene definito **dispersione delle misure**. Si osserva che non necessariamente i parametri sono scorrelati tra loro. Più le misure sono sparpagliate migliore è la precisione con cui si stimano i parametri, poichè la banda che definisce le possibili rette che fittano i dati diventa più sottile, inoltre anche il numero di misure fornisce un contributo alla precisione con cui si determinano gli stimatori.

Se calcoliamo il valore assunto dalla funzione in punto x_0 rispetto ai parametri $\hat{a}$ e $\hat{b}$ si ricava che l'errore su y_0 è dato da:

$$V[y_0] = \frac{\sigma^2}{N} \left[1 + \frac{(x_0 - \bar{x})^2}{(\bar{x}^2 - \bar{x}^2)^2} \right]$$

Più x_0 si allontana da $\bar{x}$ più è grande la varianza su y_0 .

5.14 Fit d'istogrammi




Consideriamo un insieme di N misure $\{x_i\}_i^N$ IID che seguono la pdf $f(x_i, \vec{\theta}) : \Omega \subseteq \mathbb{R} \rightarrow \mathbb{R}$, raccogliamo i dati in modo da dividere l'asse reale in k intervalli $\omega_j = [x_i, x_{i+1})$. tali che $\omega_j \cap \omega_i = \emptyset \quad \forall i, j$ e $\bigcup_{j=1}^k \omega_j = \Omega$. Tali intervalli vengono definiti 'bin', per ciascuno di essi contiamo il numero di misure n_j che cadono all'interno dell'intervallo. Complessivamente avremo che $\sum_{j=1}^N n_j = N$ numero

totale di misure. Poichè le misure sono IID a ciascuna bin associamo una probabilità:

$$p_j = \int_{\omega_j} pdf(x, \vec{\theta}) dx \quad \forall j = 1, \dots, k$$

Partendo dalla probabilità associata a ciascun bin ω_j costruiamo un istogramma i cui conteggi attesi sono dati da $E[n_j] = N \cdot p_j(\vec{\theta})$. Le misure di conteggio



dell'istogramma definito dai dati

del campione seguono una joint-pdf $pdf(n_1, \dots, n_k, p_1, \dots, p_k)$ che definisce una distribuzione multinomiale. Per $p \rightarrow 0$ le misure di conteggio sono statisticamente indipendenti tra loro di conseguenza la multinomiale può essere riscritta come prodotto di distribuzioni di probabilità binomiali.

$$pdf(n_1, \dots, n_k, p_1, \dots, p_k) = \prod_{i=1}^k pdf(n_i, p_i)$$

Nel caso in cui il valore di aspettazione del conteggio dei bin sia costante al crescere delle numero delle misure, possiamo approssimare le singole pdf binomiali come delle Poissoniane dove $\lambda_i(\vec{\theta}) = N * p_i(\vec{\theta})$ rappresenta la frequenza media di eventi per bin della distribuzione di Poisson, di conseguenza la joint-pdf diventa :

$$\prod_{i=1}^k pdf(n_i, p_i) = \prod_{i=1}^k \frac{\lambda_i(\vec{\theta})^{n_i}}{n_i!} e^{-\lambda_i} = L(n_1, \dots, n_k, \theta)$$

Che coincide con la extended likelihood.

Non solo si conosce la pdf associata ai dati ma anche il loro valore di aspettazione e varianza di conseguenza è possibile applicare il metodo di ML e dei MQ.

Osservazioni

Utilizzare le misure binnate ci permette di ridurre le dimensioni dei dati con cui si lavora, anche se si ha una perdita d'informazione questa viene bilanciata da una maggiore semplicità e dalla possibilità di usare differenti tecniche per la stima dei parametri, come per esempio quella di ML che per campioni molto grandi risulta essere da un punto di vista computazionale dispendiosa.

5.14.1 Binned Data - Minimi Quadrati

Applichiamo il metodo dei minimi quadrati confrontando i conteggi dell'istogramma dei dati con l'istogramma dei valori attesi. Dato un campione $\{x_i\}_i^N$ IID dopo averli rappresentati in un istogramma, associamo al valore

atteso di conteggi per ciascun bin l'espressione:

$$\mu_i = E[n_j] = N \cdot \int_{\omega_j} pdf(x, \vec{\theta}) dx = N \cdot p_j(\vec{\theta})$$

Scrivendo il funzionale Q^2 come:

$$Q^2 = \sum_{i=1}^K \frac{(n_i - E[n_i])^2}{V[n_i]} = \sum_{i=1}^K \frac{(n_i - Np_i(\vec{\theta}))^2}{Np_i(\vec{\theta})}$$

Assumendo che i conteggi n_i seguano una pdf Poiss(n_i, μ_i) (la discussione che segue risulterebbe verificata ugualmente anche se le pdf fossero binomiali). Per $Np_i \rightarrow \infty$ possiamo approssimare la poissoniana a una gaussiana con valore atteso e varianza pari a μ_i , di conseguenza Q^2 dipendente da variabili aleatorie distribuite secondo una gaussiana, ed essendo lui stesso una variabile casuale si ha che segue la distribuzione di $\chi^2(K - s)$ dove s è il numero di parametri. Definiamo dunque il χ^2 nella forma di **Neyman**:

$$\chi_{Neyman}^2 = \sum_{i=1}^K \frac{(n_i - \mu_i(\vec{\theta}))^2}{n_i} = \sum_{i=1}^K \frac{(O_i - E_i)^2}{O_i} \quad (5.27)$$

Dove per n_i grande si è approssimata la $V[n_i] \approx n_i$. La necessità di approssimare i dati a una Gaussiana e la varianza al numero di conteggi di un bin, è determinata dal fatto che così facendo il teorema di Gauss-Markov risulta soddisfatto poichè tra le ipotesi è necessario che i momenti non dipendano dai parametri. In conclusione si procede a minimizzare il χ_{Neyman}^2 per determinare i parametri $\vec{\theta}$. Gli stimatori $\hat{\theta}$ ottenuti con questo metodo prendono in nome di B.A.N. (Best Asymptotically Normal). Ovvero per $N \rightarrow \infty$ seguono una distribuzione normale e ha asintoticamente la varianza minima tra possibili stimatori.

Procedura di fit di un istogramma

La procedura di fit di un istogramma con il metodo del χ^2 di Neyman prevede quindi di:

- verificare che sia rispettata l'ipotesi pdf(n_i) gaussiana;

- associare a n_i un errore $\sqrt{n_i}$
- calcolare i valori attesi μ_i dei conteggi in ciascun bin;
- minimizzare il χ^2_{Neyman} trovando il valore di θ per cui l'accordo valori misurati - valori attesi è il migliore;
- all'occorrenza effettuare un test del χ^2

Se $N \cdot p_i$ è piccolo, la distribuzione binominale/poissoniana non è approssimabile a una Gaussiana. Ne consegue che Q^2 non è approssimabile ad un χ^2 e la varianza non è approssimabile con n_i , in questi casi il metodo dei MQ non è utilizzabile.

5.14.2 Binned Data - Maximum Likelihood

Fare il fit di un'istogramma quando non vale l'approssimazione Gaussiana prevede necessariamente l'utilizzo della binned Maximum Likelihood. Analogamente a quanto discusso a inizio sezione si procede a passare discretizzare il modello. Dove la funzione di likelihood associata al campione è data da

$$L(n_1, \dots, n_k, \vec{\theta}) = \prod_i^k \text{Bin}(n_i, p_i(\vec{\theta}, N))$$

e si procede a massimizzare la funzione di likelihood:

$$\frac{\partial L(\vec{n}, \vec{\theta})}{\partial \theta_j} = 0 \quad \forall j = 1, \dots, k$$

Se gli eventi seguono una distribuzione di Poisson (N la dimensione del campione non è fissata) si ha che:

$$L(n_1, \dots, n_k, \theta) = \prod_{i=1}^K \frac{\mu_i^{n_i}}{n_i!} e^{-\mu_i}$$

dove

$$\mu_i = \frac{\mu^N}{N!} e^{-\mu} \cdot p_i(\theta) = \frac{\mu^N}{N!} e^{-\mu} \cdot \int_{w_j} pdf(x, \theta) dx$$

Gli stimatori $\hat{\theta}_{ML}$ ottenuti con questo modo godono della proprietà di essere B.A.N.

Osservazioni

Ad un bin-size deve essere associata una probabilità $p_i(\vec{\theta})$ piccola. Non è necessario che i bin abbiano tutti la stessa dimensione, possiamo sceglierle in modo che $N \cdot p_i$ sia grande e quindi valga l'approssimazione Gaussiana. L'operazione di binning, fa perdere informazione, questo si può riflettere sull'incertezza del parametro stimato, ma anche sulla capacità di verificare che i dati siano ben descritti dal modello. In questi casi è utili studiare la dipendenza del risultato dal binning.

5.15 Capitolo 5 - Guida allo studio

1. Che cosa è la verosimiglianza?
2. Che cosa sostiene il teorema di Cramér-Rao?
3. Che cosa è il metodo della massima verosimiglianza?
4. Quali sono le proprietà degli stimatori ottenuti da questo metodo e in quali condizioni valgono?
5. Che differenza c'è fra la stima della varianza di uno stimatore ottenuto con il metodo della massima verosimiglianza con un numero finito di misure, rispetto al caso asintotico?
6. Che forma funzionale ha la verosimiglianza, asintoticamente, nei parametri?
7. Come si determina l'incertezza associata agli stimatori di massima verosimiglianza?
8. Che cosa è la verosimiglianza estesa ed in quali contesti si applica?

9. Su quale principio si fonda il metodo dei minimi quadrati per costruire uno stimatore?
10. Come si pu determinare la varianza di uno stimatore ottenuto con il metodo dei minimi quadrati?
11. Che cosa è il modello lineare ed in quali ipotesi è costruito?
12. Che conseguenze comporta per il modello lineare il caso in cui gli scarti siano distribuiti in modo Gaussiano?
13. Come si pu sfruttare questo fatto per determinare la varianza delle misure lungo l'asse y ?
14. Che cosa sostiene il teorema di Gauss-Markov?
15. Come si utilizzano i risultati di un fit per effettuare interpolazioni ed estrapolazioni di un andamento $y = g(x)$?
16. Come si può utilizzare il metodo dei minimi quadrati nel caso di misure binnate?
17. Che caratteristiche hanno gli stimatori ottenuti con questa tecnica?
18. Come si pu utilizzare il metodo della massima verosimiglianza nel caso di misure binnate?
19. Che caratteristiche hanno gli stimatori ottenuti con questa tecnica?
20. Che differenza c'è fra i due metodi e quando uno è preferibile rispetto all'altro?

CAPITOLO 6

Test d'ipotesi

6.1 Test del χ^2

Consideriamo un campione di N misure $\{(x_i, y_i)\}_i^N$ IID legate tra loro da una funzione $y = \psi(x, \vec{\theta})$ avremo che le misure campionate rispetto alla variabile aleatoria y , possono essere riscritte come $y_i = \psi(x, \vec{\theta}) + \epsilon_i$ dove ϵ ipotizziamo essere una variabile aleatoria la cui $pdf(\epsilon)$ segue una distribuzione di probabilità Gaussiana. Nell'ipotesi in cui valga il TCL per le ϵ_i , si ha che il Q^2 associato alle misure e il modello segue la distribuzione di $\chi^2(N - k)$.





Figura 6.1: Due modelli differenti che interpolano lo stesso campione di dati.

Nel caso di destra in figura 6.1 gli scarti quadratici sono minori, mentre in quello di sinistra sono più grandi, di conseguenza possiamo aspettarci che il valore di aspettazione della distribuzione di χ^2 del modello di sinistra sia


più grande di quello di destra. Definiamo il modello non corretto (quello di sinistra) H_1 e il modello corretto (quello di destra) H_0 , la domanda che possiamo porci è: " Se partiamo da due ipotesi H_1 e H_0 e non sappiamo quale delle due sia corretta, come facciamo a determinare quella che descrive meglio la realtà sperimentale? ".

Introduciamo una nuova quantità definita **p-value** che ha la seguente espressione :

$$\text{p-value} = \int_{Q^2}^{\infty} \chi^2(N-k) d\chi^2 \quad (6.1)$$


la quantità così definita risulta essere una misura di probabilità. Per rispondere alla domanda precedente fissiamo una soglia di tolleranza del p-value oltre alla quale i valori ottenuti risultano essere dei **falsi negativi**. Riprendendo i modelli H_0 e H_1 che definiamo rispettivamente **null hypothesis** e **alternative hypothesis**, fissata una soglia del p-value, e definita una statistica x associata (come per esempio il Q^2) al $\chi^2(x|N-k)$ avremo che:

- H_0 è rigettata se x cade nella regione in azzurro ω_α^* in figura 6.2
- H_0 è accettata se x cade nella regione in verde ω_α nella figura sottostante.






Dunque date due ipotesi H_0 e H_1 decidiamo di considerare affermativa quella che restituisce il valore del p-value piú alto (ovvero quella con probabilità maggiore) rispetto al valore p_0 di soglia considerato, apparentemente sembrerebbe sufficiente per concludere quale delle due ipotesi sia verifica, ma in realtà come si vedrá nelle sezioni successive la realtà sperimentale é piú complicata e posso esserci casi di falso positivi.

Su quanto discusso fino ad ora possiamo fare le seguenti osservazioni:

- I minimi quadrati permettono di calcolare il Q^2 (e anche il metodo di ML calcola i parametri $\hat{\theta}$ da cui si pu calcolare il Q^2);
- Il test del χ^2 é applicabile se sappiamo calcolare il valore del $Q^2 \Rightarrow \sigma^2$ deve essere nota e ben stimata;
- Test del χ^2 é un test integrale $\Rightarrow$ Somma gli scarti su tutti gli eventi, e dunque può presentare delle limitazioni (esempio sotto).

Esempio



Assumiamo che il p-value sia accettabile ovvero maggiore dell'intervallo di confidenza. Consideriamo gli stessi punti riorganizzati in un modo diverso, ma con stesso scarto quadratico. I due set di dati con y differenti hanno lo stesso p-value.


Essendo che il test del χ^2 ha una forma integrale, se graficamente si osserva una distribuzione differente delle misure, il test non lo tiene in considerazione.

Se consideriamo una dispersione delle misure come nella terza figura e assumiamo che abbia il medesimo p-value delle altre due, si ha che il test non considera che i dati diminuiscono di valore

lungo l'asse delle ordinate e dunque si ottiene un **falso positivo**, ovvero p-value è verificato, ma il modello non descrive adeguatamente il comportamento dei dati sperimentali. Il fatto che il test del χ^2 abbia forma integrale limita la generalità con cui possiamo decidere se il risultato ottenuto sia affidabile o meno.

Definizione di Overfitting

Ipotizziamo di avere un fit che ha $Q^2 = 0$ e p-value-1, ovvero i dati vengono interpolati perfettamente, questo non è un buon risultato. Si ha un caso di overfitting, dove si sono introdotti così tanti parametri che il risultato del fit si è completamente adattato alle misure, perdendo qualsiasi capacità di generalizzare il modello.



6.1.1 Applicazione del test di χ^2

Se il modello è corretto $y = \psi(x, \vec{\theta})$, allora il metodo dei MQ fornisce una stima dei parametri $\vec{\theta}$ che lo descrivono. Il valore stimato dei parametri rappresenta il punto di minimo della funzione di $Q^2_{min} = Q^2(x, \vec{\theta}_{MQ})$ rispetto al campione sperimentale, tale punto di minimo coincide anche con il massimo della distribuzione di χ^2 se pdf(ϵ) seguono una distribuzione gaussiana, che è dato da $E[Q^2] = N - k$ e quindi $Q^2_{min} = N - k$.

Il χ^2 ridotto è definito come $\chi^2_0 = \frac{\chi^2}{N-k}$ ciò implica che per $\chi^2 = Q^2_{min}$ il ridotto è $\chi^2_0 \sim 1$.

Se il valore del χ^2 è lontano dal suo valore di aspettazione $N-k$ (o 1 nel caso si usi quello ridotto), possiamo concludere che alcune delle ipotesi precedenti non sia corrette e dunque **i dati non confermano il modello**.

Le regioni a bassi valori di χ^2 corrispondono a scarti tra modello e dati molto piccoli, quindi a casi di overfitting. Tali risultati sono altamente improbabili e possono essere dovuti a sovrastime degli errori, la loro pdf non è Gaussiana o se le incertezze considerate non sono solo di natura sistematica.




Figura 6.2: Overfitting

6.1.2 Distribuzione di probabilità del p-value

Poiché Q^2 é una variabile aleatoria anche il p-value lo é e dunque possiede una sua distribuzione di probabilità, per determinarla consideriamo un cambio di variabili:

$$x : f(x) \text{ se } u^{-1}(y) = v(y) \Rightarrow y : a(x) \rightarrow g(y) = f(v(y)) \cdot |v'(y)|$$

Posto $x = Q^2$, $y = p$ e $f = \chi^2$ si ha che :

$$u(x) \rightarrow 1 - X \quad X(x) = \int_{-\infty}^x \chi^2(t, n) dt \quad e \quad v(y) = (1 - X)^{-1}$$

e quindi:

$$g(y) = \chi^2(Q^2) \left| \frac{1}{(1 - X)'(Q^2)} \right| = \frac{\chi^2(Q^2)}{\chi^2(Q^2)} = 1$$

di conseguenza il p-value segue una **distribuzione uniforme**.

Un test che é possibile fare per verificare se le condizioni iniziali affinché il test del χ^2 sia applicabile é quello di verificare che ripetendo le misure il p-value segua una distribuzione uniforme.

6.2 Errori di test statistici


Quanto discusso in questa sezione fa riferimento al test del χ^2 , ma generalizzabile a qualsiasi statistica β per cui è possibile definire due distribuzioni di probabilità:

- $pdf(\beta|H_0) = \text{Null Hypothesis}$
- $pdf(\beta|H_1) = \text{Alternative Hypothesis}$

6.2.1 Errori del I° tipo

Un errore del primo tipo rappresenta il numero di casi veri per la null hypothesis H_0 che scartiamo fissata una soglia del p-value.

$$\alpha = \int_{\bar{Q}^2}^{\infty} \chi^2(N-k) d\chi^2 \quad (6.2)$$




Il termine α prende il nome di **size del test**.

6.2.2 Errori del II° tipo

Un errore del secondo tipo rappresenta la probabilità di accettare H_0 quando è vera H_1 , in questo caso si parla di **falsi positivi**.

$$\beta = \int_{\bar{Q}^2}^{\bar{Q}^2} \chi^2(N-k) d\chi^2 \quad (6.3)$$



Si sta commettendo un errore poichè se H_1 è la forma funzionale sbagliata il fit dei dati supera ugualmente il test del χ^2 .

Il termine $1 - \beta$ prendere il nome di **power del test** e restituisce la probabilità di rifiutare H_0 quando H_1 è vera.

Fissate le due ipotesi alternative e definiti gli intervalli di confidenza, se si assume che l'errore di tipo uno sia quello più grave si procede scegliendo la percentuale di falsi negativi che si reputa accettabile e si cerca di definire gli intervalli ω_α e ω_α^* in modo tale che β sia il minore possibile (minor caso di falsi positivi). Il test così descritto viene definito il più potente per un determinato valore di soglia del p-value.

6.3 Test di Kolgomorov-Smirnov

Consideriamo un insieme di N misure della stessa grandezza fisica X vogliamo testare la null hypothesis H_0 che siano campionamenti di una determinata pdf che prendiamo come riferimento. Una possibilità è di usare il test del χ^2 applicandolo agli istogrammi costruiti con le misure raccolte e la pdf-modello. Tale procedura è corretta, ma richiedere di binnare i dati e dunque si ha una perdita d'informazione, inoltre l'esito del test può dipendere dal binning scelto per la costruzione degli istogrammi.

L'alternativa è data dal test di **Kolgomorv-Smirnof** che confronta le due distribuzioni cumulative (dati - pdf-modello) e in questo modo sfrutta tutta l'informazione contenuta nei dati. Tale test è di tipo non parametrico ovvero non richiede la costruzione di stimatori rispetto ai dati raccolti sperimentalmente e viene utilizzato per variabili aleatorie continue.


6.3.1 Costruzione del test

Date N misure ordinate in senso crescente, ricostruiamo la distribuzione cumulativa della pdf-modello, definendo una funzione a gradini $S_n(x)$ rispetto ai dati del campione, tale funzione prende il nome di **EDF (Empirical Distribution Function)**, la scelta ricade su una funzione di questo tipo poichè sono presenti dei buchi nell'informazione (campione) raccolta. La forma dell'EDF è data:

$$S_n(x) = \sum_{i=1}^n I(x_i \leq x) \quad (6.4)$$

dove la funzione $I(x_i \leq x)$ prende il nome di **indicator function** ed é espressa come:

$$I(x) = \begin{cases} 1 & x \leq x_{i+1} \\ 0 & \text{altrimenti} \end{cases}$$



Ci si domanda quanto bene S_n approssimi la cumulativa $F(x)$, la risposta è che dipende dal numero di misure contate prima del gradino successivo e quindi da come si scelgono gli intervalli. Per valutare l'approssimazione per ogni punto distinto che costituisce un estremante degli intervalli $\tilde{x}$ valutiamo l'estremo superiore della differenza tra la EDF e la pdf con cui vogliamo confrontarla:

$$D_n = \sup_x |S_n(x) - F(x)|$$

la distanza $d_n \equiv \sqrt{n}D_n$ definisce il valore di riferimento per il test di KS che consiste nel confrontare tale numero con una grandezza di riferimento d_0 , che costituisce la quantità di soglia rispetto alla quale rigettare la null hypothesis H_0 . Se $d > d_0$ l'ipotesi di compatibilità viene rigettata. Il valore di d_0 è scelto in base alla probabilità che la variabile casuale d sia maggiore di d_0 quando il modello è corretto.

$$P(d > d_0 | H_0) = \alpha$$

Tale metodo non parametrico è anche utile per confrontare due campioni di dati al fine di determinare se provengono dalla stessa popolazione. Si noti anche che la **EDF**(**x**) costruita è anch'essa una distribuzione cumulativa di probabilità.

6.4 Confronto di una misura con il valore di riferimento

6.4.1 Distribuzione t-student

Si consideri un campione di N misure di cui si è calcolata la media campionaria $\bar{x} = \frac{1}{N} \sum x_i$ e si supponga di conoscere σ_i delle singole misure e $E[x] = \mu$, allora la media aritmetica $\bar{x}$ è per il TCL è distribuita come una gaussian $G(\bar{x}, \mu, \frac{\sigma}{\sqrt{N}})$. Come facciamo a dire che $\bar{x}$ e μ sono sufficientemente vicine tra loro rispetto alle incertezze ?

Per determinare la distanza tra le grandezze definiamo la distribuzione t-student data dalla variabile aleatoria:

$$t = \frac{|\bar{x} - \mu|}{\frac{\sigma}{\sqrt{N}}}$$

definita rispetto al caso descritto nelle righe precedenti. In generale la t-student per un parametro è data da:

$$t = \frac{|\hat{\theta}^* - \theta_t|}{\sigma_{\theta^*}} \quad (6.5)$$

Notare che nel caso in cui si conoscano a priori l'incertezza della misura che si sta confrontando, dunque non si è ottenuta mediante un processo statistico si ha che la pdf(t) é Gaussiana. Se $\bar{x}$ segue una pdf Gaussiana e $Q^2 \sim \chi^2(N-1)$ la distribuzione di t-student ha la seguente forma funzionale.

$$f(t, \nu = N-1) = \frac{1}{\sqrt{n\nu}} \cdot \frac{\Gamma(\frac{\nu+1}{2})}{\Gamma(\frac{\nu}{2})} \cdot \left(1 + \frac{t^2}{\nu}\right)^{-\left(\frac{\nu+1}{2}\right)} \quad (6.6)$$

Proprietà della distribuzione

$$\mu = E[t] = 0 \qquad \gamma_1 = 0$$

$$\sigma^2 = V[t] = \frac{\nu}{\nu-2} \quad \nu > 2 \qquad \gamma_2 = \frac{6}{\nu-4} \quad \nu > 4$$

Per $\nu = g.d.l. \rightarrow \infty$ la distribuzione diventa Gaussiana. Si osserva che la pdf della t-student è un po' più larga della distribuzione Gaussiana (fig 6.2).




Figura 6.3: Confronto distribuzioe di Gauss e t-student


In generale possiamo vedere la distribuzione della t-student come il rapporto tra una Gaussiana normalizzata e la radice di $\frac{\chi^2}{N-1}$.

$$t = \frac{|\bar{x} - \mu|}{\left[\frac{\hat{\sigma}^2}{N}\right]^{\frac{1}{2}}} = \frac{|\bar{x} - \mu|}{\left[\frac{\sigma^2}{N}\right]^{\frac{1}{2}}} \cdot \frac{\left[\frac{\sigma^2}{N}\right]^{\frac{1}{2}}}{\left[\frac{\hat{\sigma}^2}{N}\right]^{\frac{1}{2}}} = \frac{|\bar{x} - \mu|}{\left[\frac{\sigma^2}{N}\right]^{\frac{1}{2}}} \cdot \left[\frac{\chi^2}{N-1}\right]^{\frac{1}{2}}$$

la parte in azzurro segue la pdf di una Gaussiana normalizzata $N(0,1)$, mentre la parte in rosso segue $\frac{\chi^2}{N-1}$. Dove:

$$\frac{1}{\left[\frac{\sigma^2}{N}\right]^{\frac{1}{2}}} = \frac{1}{\left[\frac{N-1}{\chi^2}\right]^{\frac{1}{2}}} = \left[\frac{\chi^2}{N-1}\right]^{\frac{1}{2}}$$

Per la t-student fissato un valore di soglia t_0 , ci permette di determinare la compatibilità tra il valore stimato e quello atteso, se $t > t_0$ allora le due misure risultano essere non compatibili tra loro. Dove gli intervalli di compatibilità risultano essere in multipli di deviazioni



standard.

Confronto tra la stima di due parametri


La distribuzione di t-student può essere utilizzata non solo per confrontare una misura con un valore atteso, ma anche due stime del medesimo parametro tra loro.

$$z = \frac{|\theta_1^* - \theta_2^*|}{\left[\frac{\hat{\sigma}_1^2}{N} + \frac{\hat{\sigma}_2^2}{N}\right]^{\frac{1}{2}}} \quad (6.7)$$

dove la pdf(z) è Gaussiana se σ_1 e σ_2 sono senza errore, mentre altrimenti segue una distribuzione di t-student con $N-M-2$ gradi di libertà.

6.5 Intervalli di confidenza

Ipotizziamo che lo stimatore $\hat{\theta}$ segue una distribuzione gaussiana $G(\hat{\theta}, \theta_t, \sigma)$ determinato il suo valore θ^* ci domandiamo quale sia la probabilità che tale valore disti σ dal valore vero θ_t , ovvero $P[\theta^* \in (\theta_t - \sigma, \theta_t + \sigma)] = 0,68$. Essendo θ^* una variabile aleatoria dipendente dal campione mentre θ_t no, l'affermazione precedente non è corretta, in quanto θ_t non è una variabile aleatoria, per questo motivo riscriviamo l'intervallo di confidenza in $\theta_t \in (\theta^* - \sigma, \theta^* + \sigma)$ e la probabilità come $P[\theta_t \in (\theta^* - \sigma, \theta^* + \sigma)] = 0,68$, determinando un 68 % di confidenza nell'intercettare θ_t ripetendo l'esperimento.



6.5.1 Metodo della cintura di confidenza


Definiamo uno stimatore $\hat{\theta} \equiv \hat{\theta}(x)$, di un parametro θ rispetto ad un campione di N variabili aleatorie IID di una grandezza x , poichè lo stimatore dipende da variabili aleatorie anch'esso è una r.v. di conseguenza seguirà una distribuzione di probabilità $f(\hat{\theta} | \theta)$. Per ciascun campione raccolto $\hat{\theta}$ definirà una stima θ^* del parametro, costruendo la pdf associata. Ripetendo l'esperimento con diversi campionamenti ciascuna distribuzione relativa avrà un valore atteso $E[\hat{\theta}] = \theta_t^i$ e una varianza $V[\hat{\theta}] = \sigma_{\theta_t^i}^2$. Per ciascun esperimento non conosciamo la forma analitica della pdf oppure non siamo in grado di definirla di conseguenza per stimare l'intervallo di confidenza di un certo valore di θ^* stimato usiamo il seguente metodo:

- Per ogni valore di θ_t^i definiamo $pdf_i(\hat{\theta} | \theta_t)$;

- Si determinano i punti della pdf($\hat{\theta} | \theta_t$) che definiscono un intervallo di confidenza per il θ_t corrispettivo;

- Si tracciano due rette parallele che attraversano ciascuna i punti estremanti di ciascun intervallo di confidenza, definendo una banda nel piano (θ_t, θ^*) che prende il nome di **Confidence Band**.

Quando si effettua una misura si trova θ^* e dove tale valore interseca la confidence band, punti d'intersezione determinano l'intervallo di confidenza di θ_t . Si dimostra che l'intervallo trovato ha copertura uguale a quello scelto per le singole p.d.f.






Figura 6.4: Banda di confidenza ed intervallo di confidenza

6.6 Discovery Significance

Consideriamo di rilevare un numero di eventi n_0 in un intervallo di tempo, e che tale numero di eventi può essere distinto in due sotto categorie date da n_s che è il numero di eventi dovuto a un processo fisico e n_b numero di eventi che definiscono il "rumore di fondo" (e rappresenta fenomeni non legati al processo fisico osservato) dove $n_0 = n_s + n_b$. A priori non abbiamo modo di sapere nel conteggio quanti fenomeni fisici e non compongano n_0 . In compenso conosciamo il numero medio di eventi di entrambi i conteggi $E[n_s] = \nu_s$ e $E[n_b] = \nu_b$.

Costruiamo la nostra null hypothesis H_0 assumendo che del numero complessivo di fenomeni buona parte siano dati dal rumore di fondo; per confutare tale ipotesi utilizzando il p-value è necessario che questo sia più piccolo del valore di soglia p_0 , in fisica delle particelle si sceglie $p_0 = 3 \times 10^{-7}$ per il segnale che una particella sia stata rilevata. La Poissoniana che descrive la probabilità di n_b è data da:

$$Poiss(n_b, \nu_b) = \frac{\nu_b^n}{n!} e^{-\nu_b}$$

la probabilità di misurare un valore n_b di quello misurato è data da:

$$\beta = P(n > n_b^0) = \sum_{k=n_b^0+1}^{\infty} \frac{\nu^k}{k!} e^{-\nu} = 1 - \sum_{k=0}^n \frac{\nu^k}{k!} e^{-\nu} \quad (6.8)$$

Possiamo riscrivere l'equazione (6.7) come:

$$1 - \beta = \sum_{k=0}^n \frac{\nu^k}{k!} e^{-\nu} \approx \int_{2n_b^0}^{\infty} \chi^2(2n+2) d\chi^2 \quad (6.9)$$

approssimabile alla distribuzione del $\chi^2(2n+2)$ con $2(n+1)$ g.d.l., ovvero l'espressione di sinistra della 6.8 coincide con la sua c.d.f. Di conseguenza avremo che il:

$$\text{p-value} = 1 - \beta$$

Per $\beta \approx 1$ il p-value è molto piccolo e quindi possiamo rigettare la null hypothesis H_0 formulata all'inizio e quindi il segnale osservato è effettivamente un processo fisico. Un valore grande di β ci dice che si ha un alta probabilità che per valori più grandi di n_b^0 i fenomeni osservati siano composti per la maggior parte da rumore di fondo. Mentre per $1 - \beta$ molto piccolo si ha una bassa probabilità che quanto osservato sia dato da rumore di fondo.

6.7 Studio dei Residui e Pulls

6.8 Capitolo 6 - Guida allo studio

1. Come funziona il test del chi quadrato per decidere la bontà di un fit?
2. Entro quali ipotesi il test funziona?
3. Che cosa è il p-value associato al test?
4. Quali sono le informazioni minime necessarie per poterlo calcolare?
5. Quali sono le limitazioni del test del chi2?

6. Che cosa sono gli errori di primo e di secondo tipo e come sono associati al test del χ^2 ?
7. Che distribuzione attesa ha il p-value ottenuto dal test del χ^2 ?
8. In quali circostanze si utilizza la distribuzione di t-Student per l'analisi dei dati?
9. In che cosa consiste il test di Kolmogorov?
10. In che cosa consiste il test di t-Student?
11. Che caratteristiche ha la distribuzione di t-Student e come si comporta al limite per il numero di gradi di libertà che tende all'infinito?
12. Come si fa operativamente a disegnare la distribuzione di Kolmogorov?
13. Come si costruisce una confidence belt?
14. Come si pu determinare la significatività di scoperta di un segnale sovrapposto a rumore di fondo?

Bibliografia

- [1] Slide del corso di Laboratorio di calcolo e statistica del secondo anno di Fisica, università di Milano Bicocca, Maura Pavan, 2022/2023
- [2] Appunti manoscritti presi durante le lezioni frontali tenute dal prof. Pietro Govoni per il corso di Laboratorio di calcolo e statica del secondo anno di Fisica, Università di Milano Bicocca
- [3] Data Analysis Technique for Physical Scientist, Pruneau, Cambridge Univeristy Press, 2017
- [4] Statistical Data Analysis, Glen Cowan, Clarendon Press, 1998
- [5] Statistical Methods in Data Analytics, Metzger