

CHAPTER 3

Distribuzioni di probabilità multidimensionali

3.1 Probabilità per variabili aleatorie in più dimensioni

Quando un evento è identificato da un vettore \underline{x} , si parla di distribuzioni di probabilità multidimensionali. Per cui risultano verificati gli assiomi di Kolgomorov.


$$f(\underline{x}) : \mathbb{R}^n \rightarrow \mathbb{R}^+$$

e la cdf per estensione della definizione mono-dimensionale è:

$$cdf(\underline{x}) = \int_{-\infty}^{\underline{x}} f(\underline{x}) \cdot d\underline{x}$$

la probabilità di un evento per una variabile continua \underline{x} è definita su una regione di spazio $A \subseteq \mathbb{R}^n$:

$$P(\underline{x} \in A) = \int_A f(\underline{x}) \cdot d\underline{x}$$



3.2 Distribuzione di probabilità marginale

Data una distribuzione di probabilità multidimensionale $\text{pdf}(x_1, \dots, x_n)$ si definisce **distribuzione di probabilità marginale**:

$$f_{x_i}(x_1, \dots, x_i, \dots, x_n) = \int \text{pdf}(x_1, \dots, x_i, \dots, x_n) dx_1 \cdots dx_n \quad (3.1)$$




Figure 3.1: Distribuzione di probabilità marginale per una $\text{pdf}(x,y)$

3.3 Distribuzione di probabilità condizionata

Per semplicità consideriamo una distribuzione di probabilità rispetto a due variabili aleatorie x ed y e le rispettive distribuzioni marginali f_x e f_y . Vogliamo determinare la probabilità che $P(x|y = y_0)$ o $P(y|x = x_0)$. Consideriamo due eventi $A, B \subset \Omega$ disgiunti. Possiamo identificare le pdf come:

- $P(A \cap B) \rightarrow$ joint pdf
- $P(A) \rightarrow$ pdf marginale
- $P(A|B) \rightarrow$ pdf condizionata

Definiamo L'evento $A = \{y \mid x \in [x_0, x_0 + dx] , y \in \mathbb{R}\}$ e l'evento $B = \{x \mid y \in [y_0, y_0 + dx] , x \in \mathbb{R}\}$. Le probabilità associate ai singoli

eventi sono $P(A) = f_x$ e $P(B) = f_y$. Mentre la probabilità congiunta è $P(A \cap B) = \int pdf(x_0, y_0) dx dy$.

Di conseguenza possiamo scrivere la probabilità condizionata come:

$$pdf(x|y = y_0) = P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{pdf(x, y_0)}{f_x(y_0)} \quad (3.2)$$

Tale risultato ci riconduce al fatto che le componenti di \underline{x} possono essere statisticamente indipendenti tra di loro e dunque nel caso lo fossero possiamo riscrivere la $pdf(\underline{x})$ come:

$$pdf(x_1, x_2, \dots, x_n) = pdf(x_1) \cdot pdf(x_2) \cdots pdf(x_n) \quad (3.3)$$

3.4 Varianza di una pdf multidimensionale

Nel caso della Varianza, le componenti di una variabile aleatoria multidimensionale \underline{x} possono essere legate tra loro, ovvero avere una relazione nel modo in cui variano, tale legame prende il nome di **covarianza**. Per due componenti x_i e x_j con $i \neq j$ si ha che:

$$\sigma_{i,j}^2 = E[(x_i - \mu_i)]E[(x_j - \mu_j)] = E[(x_i - \mu_i)(x_j - \mu_j)] \quad (3.4)$$

mentre

$$\sigma_{i,i}^2 = E[(x_i - \mu_i)^2] \quad (3.5)$$

di conseguenza la varianza di una $pdf(\underline{x})$ multidimensionale è rappresentata da una matrice che prende il nome di **matrice di covarianza** ed ha dimensione $n \times n$ nel caso \underline{x} abbiamo dimensione n .

$$V[\underline{x}] = \begin{bmatrix} V[x_1] & \cdots & Cov[x_1, x_n] \\ \vdots & \ddots & \vdots \\ Cov[x_n, x_1] & \cdots & V[x_n] \end{bmatrix} \quad (3.6)$$

Nel caso in cui le componenti della variabile aleatoria \underline{x} siano indipendenti tra loro si ha che la covarianza è nulla e dunque la (3.3) diventa una matrice

diagonale.

$$V[\underline{x}] = \begin{bmatrix} V[x_1] & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & V[x_n] \end{bmatrix} \quad (3.7)$$

La covarianza gode delle seguenti proprietà:

- Avere $Cov[x_i, x_j] = 0$ non implica necessariamente che le due variabili aleatorie siano statisticamente indipendenti.
- Se due variabili aleatorie sono statisticamente indipendenti
 $\Rightarrow Cov[x_i, x_j] = 0$
- Se due variabili aleatorie sono linearmente dipendenti
 $\Rightarrow Cov[x_i, x_j] = 0$




Figure 3.2: Esempi di come la covarianza si presenta in una distribuzione

3.5 Correlazione

Gli elementi V_{ij} della matrice di covarianza misurano il grado di correlazione tra le variabili x_i e x_j . Dato che ogni variabili mostra una varianza finita e positiva è utile confrontare la covarianza rispetto alle loro rispettive varianze,

per farlo si introduce il coefficiente di correlazione:

$$\rho_{ij} = \frac{Cov[x_i, x_j]}{\sigma_i \sigma_j} \quad (3.8)$$

tale grandezza $\rho_{ij} \in [-1, 1]$.

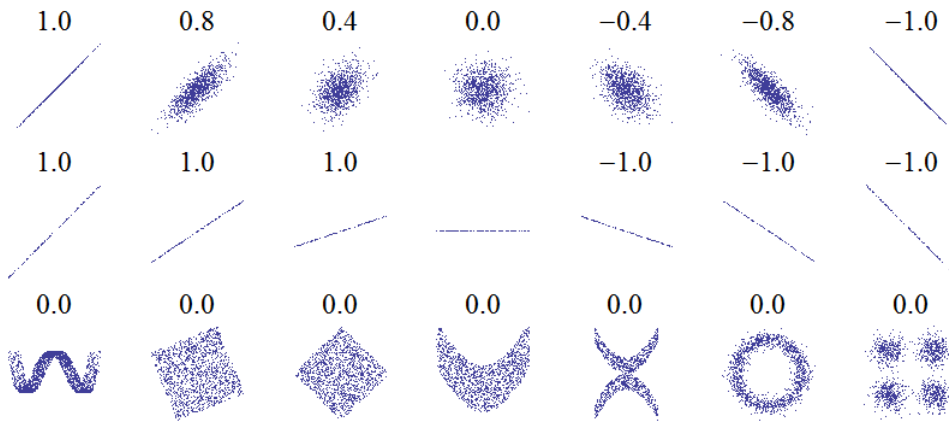


Figure 3.3: Indice di correlazione di Pearson per un campione di misure.

3.5.1 Cambiamento di variabili per una pdf multidimensionale

La matrice della varianza (3.6) è diagonalizzabile, questo vuol dire che esiste un cambio di base che la diagonalizza, in fisica è equivalente ad avere un cambio di variabile. Sperimentalmente raccolto un campione di misure esiste sempre un cambio di variabile tale per cui la matrice di covarianza è diagonalizzabile. Anche se con un cambio di variabili le grandezze diventano decorrelate $Cov[x_i, x_j] = 0$ questo non vuol dire che siano statisticamente indipendenti.

Analogamente al caso mono-dimensionale per il cambio di variabili si ha che date delle funzioni:

$$\begin{cases} x = u(\alpha, \beta) \\ y = w(\alpha, \beta) \end{cases}$$

la join pdf nelle nuove coordinate sarà data da:

$$pdf(\alpha, \beta) = pdf(x, y) \cdot |det J| \quad (3.9)$$

dove J è la matrice Jacobiana associata alla trasformazione.

3.5.2 Propagazione degli errori

Ipotizziamo di avere un insieme di N misure $\{x_i\}_i^N$ e usiamo tali valori come componenti di un vettore $\underline{x} \in \mathbb{R}^N$, descritto da una pdf(\underline{x}) di cui conosciamo $\underline{\mu}$ e matrice di covarianza $V[\underline{x}]$, vogliamo calcolare $y = u(\underline{x})$. Per farlo approssimiamo $u(\underline{x})$ con un sviluppo di Taylor al primo ordine in un intorno di $\underline{\mu}$:

$$u(\underline{x}) \approx u(\underline{\mu}) + \nabla u|_{x=\underline{\mu}} \cdot (\underline{x} - \underline{\mu})$$

Dunque i momenti della pdf(\underline{y}) sono:

$$\begin{aligned} \bullet E[y] &= E[u(\underline{\mu})] + \sum_{i=1}^n \frac{\partial}{\partial x_i} u(\underline{\mu}) E[(x_i - \mu_i)] = u(\underline{\mu}) \\ \bullet \sigma_y^2 &= E[y^2] - E[y]^2 = E[(\underline{x} - \underline{\mu})^T H(u(\underline{x}))|_{x=\underline{\mu}} (\underline{x} - \underline{\mu})] = \\ &= \sum_{i,j=1}^n \frac{\partial u(\underline{x})}{\partial x_i} \cdot \frac{\partial u(\underline{x})}{\partial x_j} \Big|_{x=\underline{\mu}} \cdot V_{ij} \end{aligned}$$

Per un caso bidimensionale l'incertezza su $y = f(x, y)$ è data da:

$$\sigma_y^2 = \left(\frac{\partial f(x, y)}{\partial x} \right)^2 \sigma_x^2 + \left(\frac{\partial f(x, y)}{\partial y} \right)^2 \sigma_y^2 + 2 \frac{\partial f(x, y)}{\partial x} \cdot \frac{\partial f(x, y)}{\partial y} Cov[x, y] \quad (3.10)$$

3.6 Distribuzione di Gauss Multidimensionale

L'espressione di una Gaussiana in più dimensioni è data da:

$$f(\underline{x} \mid \underline{\mu}, V) = \frac{1}{(2\pi)^{\frac{n}{2}} \det V^{\frac{1}{2}}} \cdot \exp \left[-\frac{1}{2} < (\underline{x} - \underline{\mu}), V^{-1}(\underline{x} - \underline{\mu}) > \right] \quad (3.11)$$

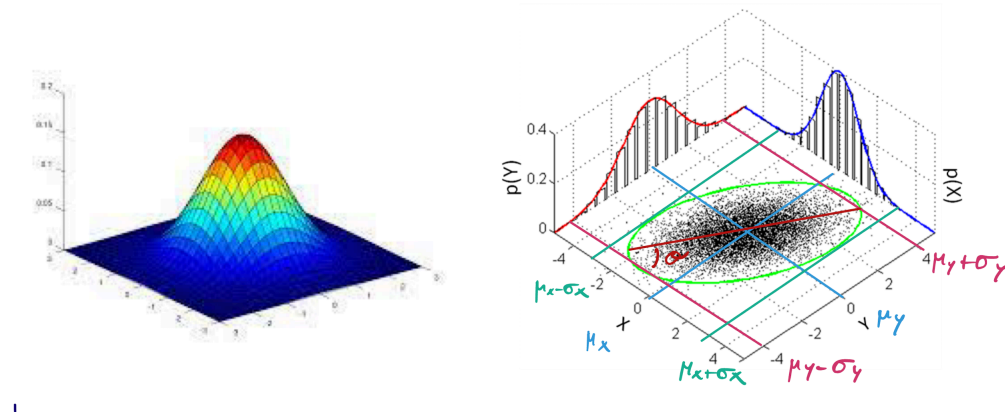


Figure 3.4: Gaussiana in due variabili (x,y) e le sue distribuzioni marginali

La gaussiana in due dimensioni in generale ha un profilo ellittico per 1σ . L'angolo d'inclinazione del semiasse maggiore è legato al coefficiente di correlazione:

$$\theta = \frac{2\rho\sigma_x\sigma_y}{\sigma_x^2 - \sigma_y^2} \quad (3.12)$$

Se esplicitiamo l'equazione (3.11) per due variabili si ha:

$$f(x, y \mid \mu_x, \mu_y, V) =$$

$$= \frac{1}{(2\pi)\sigma_x\sigma_y\sqrt{1-\rho^2}} \exp \left\{ -\frac{1}{2(1-\rho^2)} \left[\left(\frac{x-\mu_x}{\sigma_x} \right)^2 - \frac{2\rho(x-\mu_x)(y-\mu_y)}{\sigma_x\sigma_y} + \left(\frac{y-\mu_y}{\sigma_y} \right)^2 \right] \right\}$$

Se il coefficiente di correlazione di Pearson $\rho = 0$ possiamo riscrivere l'equazione precedente come:

$$\begin{aligned} f(x, y \mid \mu_x, \mu_y, V) &= \frac{1}{(2\pi)\sigma_x\sigma_y} \exp \left\{ -\frac{1}{2} \left[\left(\frac{x - \mu_x}{\sigma_x} \right)^2 + \left(\frac{y - \mu_y}{\sigma_y} \right)^2 \right] \right\} = \\ &= G(x, \mu_x, \sigma_x) \cdot G(y, \mu_y, \sigma_y) \end{aligned}$$

In generale è solo vero che due variabili statisticamente indipendenti sono anche decorrelate, nel caso Gaussiano vale anche il viceversa, ovvero se due variabili sono decorrelate allora sono anche statisticamente indipendenti.